

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Trần Nam Khánh - Phan Lê Đắc Phú

ỨNG DỤNG THỊ GIÁC MÁY TÍNH
HỖ TRỢ CHẨN ĐOÁN
HÌNH ẢNH Y KHOA

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CỬ NHÂN TÀI NĂNG

Tp. Hồ Chí Minh, tháng 07/2025

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Trần Nam Khánh - 21120015

Phan Lê Đắc Phú - 21120111

ỨNG DỤNG THỊ GIÁC MÁY TÍNH
HỖ TRỢ CHẨN ĐOÁN
HÌNH ẢNH Y KHOA

KHÓA LUẬN TỐT NGHIỆP CỬ NHÂN CNTT
CHƯƠNG TRÌNH CỬ NHÂN TÀI NĂNG

GIẢNG VIÊN HƯỚNG DẪN

ThS. Nguyễn Hải Đăng

PGS.TS. Trần Minh Triết

Tp. Hồ Chí Minh, tháng 07/2025

Lời cam đoan

Chúng tôi xin cam đoan đây là công trình nghiên cứu của nhóm sinh viên gồm Trần Nam Khánh và Phan Lê Đắc Phú dưới sự hướng dẫn của ThS. Nguyễn Hải Đăng và PGS.TS. Trần Minh Triết. Toàn bộ nội dung trong luận văn là do nhóm tác giả tự biên soạn.

Lời cảm ơn

Chúng tôi xin chân thành gửi lời cảm ơn sâu sắc đến Thầy Trần Minh Triết, Thầy Nguyễn Hải Đăng, những người đã tận tình hướng dẫn, hỗ trợ và định hướng cho chúng tôi trong suốt quá trình thực hiện khóa luận tốt nghiệp này. Sự tận tâm và kiến thức chuyên môn của các Thầy là nguồn động lực lớn giúp chúng tôi hoàn thành tốt đề tài nghiên cứu.

Chúng tôi cũng xin chân thành cảm ơn Quý Thầy Cô trong Khoa Công nghệ thông tin - Trường đại học Khoa học Tự nhiên - Đại học quốc gia Hồ Chí Minh đã trang bị cho tôi những kiến thức nền tảng quý báu trong suốt thời gian học tập tại trường, là tiền đề vững chắc để tôi có thể thực hiện khóa luận này.

Bên cạnh đó, chúng tôi xin cảm ơn gia đình, bạn bè và những người thân yêu đã luôn đồng hành, động viên và tạo điều kiện thuận lợi nhất để tôi yên tâm học tập và nghiên cứu.

Cuối cùng, chúng tôi xin cảm ơn tất cả những cá nhân, tổ chức đã trực tiếp hoặc gián tiếp giúp đỡ chúng tôi trong quá trình thực hiện và hoàn thiện khóa luận này.

Mặc dù đã cố gắng hết sức, nhưng do giới hạn về thời gian và kinh nghiệm, khóa luận không tránh khỏi những thiếu sót. Chúng tôi rất mong nhận được sự góp ý của Quý Thầy Cô và các bạn để hoàn thiện hơn trong tương lai.

Đề cương chi tiết

Bên dưới đây là bản đề cương chi tiết.



fit@hcmus

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

ĐỀ CƯƠNG KHOÁ LUẬN TỐT NGHIỆP

**ỨNG DỤNG THỊ GIÁC MÁY TÍNH HỖ TRỢ
CHẨN ĐOÁN HÌNH ẢNH Y KHOA**

(Vision-based Assistance for Medical Image Analysis)

1 THÔNG TIN CHUNG

Người hướng dẫn:

- PGS.TS Trần Minh Triết (Khoa Công nghệ Thông tin)
- ThS. Nguyễn Hải Đăng (Phòng thí nghiệm Công nghệ Phần mềm)

Nhóm sinh viên thực hiện:

1. Trần Nam Khánh (MSSV: 21120015)
2. Phan Lê Đắc Phú (MSSV: 21120111)

Loại đề tài: Nghiên cứu

Thời gian thực hiện: Từ tháng 01/năm 2025 đến tháng 07/năm 2025

2 NỘI DUNG THỰC HIỆN

2.1 Giới thiệu về đề tài

Trong bối cảnh y học hiện đại, việc ứng dụng công nghệ vào chẩn đoán và điều trị bệnh đang trở thành xu hướng tất yếu nhằm nâng cao hiệu quả và giảm thiểu sai sót trong quá trình khám chữa bệnh. Việc phát triển các kỹ thuật xử lý hình ảnh nhằm tăng độ chính xác và hiệu quả phân tích hình ảnh y khoa có thể góp phần nâng cao chất lượng chăm sóc sức khỏe.

Phân đoạn ảnh đóng vai trò quan trọng trong các kỹ thuật xử lý hình ảnh y khoa. Đây là quá trình tách các vùng quan trọng trong ảnh y khoa, giúp bác sĩ và chuyên gia y tế phân tích cấu trúc giải phẫu và phát hiện các bất thường. Phương pháp này được áp dụng trên nhiều loại hình ảnh y khoa như CT, MRI, hoặc siêu âm, hỗ trợ chẩn đoán bệnh ở cấp độ chi tiết hơn.

Một trong những bước đột phá quan trọng trong việc giải quyết bài toán phân đoạn ảnh nói chung và ảnh y khoa nói riêng y khoa là sự ra đời của U-Net [1] vào năm 2015. Đây là một kiến trúc encode-decoder với các kết tắt (skip connection) giúp bảo toàn thông tin không gian đồng thời học các đặc trưng phân cấp. U-Net giúp tăng cường tín hiệu từ các đặc trưng cục bộ dẫn đến sự gia tăng đáng kể trong chất lượng của kết quả dự đoán. Các biến thể sau này của U-Net như Attention U-Net [2] và 3D U-Net [3] đã được phát triển để cải thiện khả năng hiểu ngữ cảnh và xử lý dữ liệu thể tích.

Kể từ sự phổ biến của mô hình transformer [4] và sự phát triển của nó trên hình ảnh [5], nhiều phương pháp ứng dụng mô hình transformer vào ảnh y khoa. Nổi bật trong số đó là các phương pháp đi theo kiến trúc U-Net kết hợp giữa mạng tích chập và transformer như TransUNet [6], UNETR [7],

Tuy nhiên, vì các kiến trúc transformer thường yêu cầu nhiều tài nguyên như kích thước tập dữ liệu, mạng tích chập vẫn là kiến trúc phổ biến được sử dụng trong nhiều công trình nghiên cứu trên loại dữ liệu y khoa. Một trong những

phương pháp nổi bật nhất là nnU-Net [8]. Kết quả của nnU-Net và các biến thể của nó nổi bật trên những tập dữ liệu chuẩn cũng như các thử thách lớn trong lĩnh vực phân tích ảnh y khoa. Sự thành công của nnU-Net đến từ khả năng thích ứng và tối ưu mô hình phân đoạn ảnh cho mỗi bộ dữ liệu cụ thể thông qua việc thiết lập cấu trúc và thuật toán tiền xử lý thích hợp.

Nhìn chung, xây dựng các hệ thống phân đoạn ảnh y tế chất lượng cao luôn gặp phải rào cản lớn về dữ liệu gán nhãn. Đặc biệt với ảnh siêu âm - một trong những phương thức chẩn đoán phổ biến tại các cơ sở y tế tuyến dưới - việc gán nhãn thủ công không chỉ đòi hỏi kiến thức chuyên môn sâu mà còn tốn nhiều thời gian và công sức, do ảnh thường có nhiễu cao, biên mờ, và phụ thuộc vào kỹ năng người vận hành. Trong bối cảnh đó, Human-in-the-Loop (HITL) [9] nổi lên như một chiến lược đầy hứa hẹn, kết hợp giữa khả năng học của mô hình và sự điều hướng linh hoạt từ chuyên gia lâm sàng.

Một số hệ thống gần đây như MedUHIP [10] cho phép chuyên gia tương tác nhanh với kết quả phân đoạn ban đầu của mô hình, từ đó tạo ra các chỉnh sửa có thể được sử dụng để cập nhật mô hình theo thời gian thực. Tương tự, PRISM Lite [11] áp dụng trong ảnh siêu âm thai kỳ đã chứng minh hiệu quả của vòng lặp tương tác liên tục trong cải thiện chất lượng phân đoạn 3D với số lần can thiệp tối thiểu.

Tiến bộ hơn ta có học sâu chủ động (Deep Active Learning - DAL) [12] là một hướng tiếp cận kết hợp giữa học sâu và học chủ động, nhằm tối ưu hóa hiệu quả huấn luyện trong bối cảnh dữ liệu gán nhãn hạn chế - một đặc điểm phổ biến trong y khoa. Trong lĩnh vực ảnh y tế, DAL đã được áp dụng hiệu quả trên nhiều mô hình học sâu như U-Net [1], UNet++ [13], hoặc Swin-UNet [14] hoặc Swin UNETR [15], cùng với nhiều dạng dữ liệu hình ảnh khác nhau như ảnh hiển vi mô bệnh học (WSI) [16], ảnh siêu âm [17], và X-quang [18].

Những nghiên cứu này đã đóng góp đáng kể vào lĩnh vực phân đoạn ảnh y khoa, mở ra tiềm năng cải tiến hơn nữa trong việc giảm sự phụ thuộc vào dữ liệu có gán

nhân mà vẫn đảm bảo độ chính xác cao trong phân đoạn hình ảnh y khoa.

Trong đề tài này, chúng tôi tập trung nghiên cứu và ứng dụng các kỹ thuật phân đoạn hình ảnh y khoa tiên tiến kết hợp với mô hình học sâu trong trí tuệ nhân tạo. Mục tiêu chính là giảm thiểu sự phụ thuộc vào dữ liệu có gán nhãn trong quá trình huấn luyện mô hình, đồng thời duy trì độ chính xác cao, từ đó tối ưu hóa tài nguyên và nâng cao tính ứng dụng thực tế của hệ thống.

2.2 Lý do thực hiện

Việc phân tích hình ảnh y khoa đóng vai trò quan trọng trong việc phát hiện sớm và chẩn đoán chính xác các bệnh lý phức tạp. Tuy nhiên, phương pháp chẩn đoán truyền thống chủ yếu dựa vào kinh nghiệm của bác sĩ, điều này có thể dẫn đến những hạn chế nhất định, chẳng hạn như sai sót do yếu tố chủ quan hoặc quá tải công việc. Do đó, việc nghiên cứu và phát triển một hệ thống hỗ trợ chẩn đoán hình ảnh y khoa dựa trên trí tuệ nhân tạo không chỉ mang lại lợi ích to lớn cho ngành y tế mà còn giúp cải thiện chất lượng điều trị cho bệnh nhân.

Hệ thống phân đoạn hình ảnh y khoa được xây dựng với mục tiêu hỗ trợ các chuyên gia y tế trong việc nâng cao độ chính xác trong chẩn đoán. Bằng cách ứng dụng các kỹ thuật xử lý ảnh tiên tiến, hệ thống có khả năng phân đoạn hình ảnh từ nhiều nguồn khác nhau như MRI, CT-Scan và Ultrasound, từ đó nhận diện chính xác hơn các dấu hiệu bệnh lý so với các phương pháp truyền thống. Hệ thống không chỉ giúp giảm thiểu rủi ro do sai sót trong chẩn đoán mà còn tạo điều kiện để các bác sĩ có thể tập trung hơn vào những ca bệnh phức tạp, tối ưu hóa thời gian và nguồn lực trong điều trị.

Bên cạnh việc hỗ trợ chẩn đoán, hệ thống còn đóng vai trò như một công cụ hữu ích giúp bác sĩ có thêm thông tin để đưa ra quyết định nhanh chóng và chính xác, hỗ trợ chuyên gia y tế phát hiện những dấu hiệu bất thường mà mắt người có thể bỏ sót, đặc biệt là trong các trường hợp bệnh lý hiếm gặp hoặc khó phát hiện. Ngoài ra, hệ thống còn có tiềm năng giảm bớt áp lực cho đội ngũ y bác sĩ

tại các cơ sở y tế có lượng bệnh nhân đông, nơi mà việc chẩn đoán nhanh chóng và chính xác là yếu tố quan trọng trong việc cứu chữa kịp thời.

Nhìn chung, việc sử dụng mô hình học sâu trí tuệ nhân tạo trong phân đoạn hình ảnh y khoa không chỉ mang lại lợi ích thiết thực trong chẩn đoán bệnh mà còn tạo tiền đề cho nhiều ứng dụng khác trong lĩnh vực y học số. Hệ thống có thể được tích hợp vào phần mềm y tế, hỗ trợ bác sĩ trong quá trình chẩn đoán, đặc biệt tại các bệnh viện lớn có khối lượng dữ liệu cao và nhân lực hạn chế. Hơn nữa, nghiên cứu này không chỉ đóng góp vào việc nâng cao chất lượng chẩn đoán mà còn mở đường cho các ứng dụng y học tiên tiến trong tương lai, giúp cải thiện hệ thống chăm sóc sức khỏe toàn diện hơn.

2.3 Mục tiêu đề tài

Nghiên cứu của chúng tôi xem xét các yếu tố ảnh hưởng đến hiệu suất của mô hình, bao gồm chất lượng dữ liệu đầu vào, phương pháp tiền xử lý hình ảnh và các kỹ thuật tối ưu hóa trong quá trình huấn luyện. Việc phân tích các yếu tố này giúp cải thiện độ chính xác và độ tin cậy của hệ thống, đồng thời đề xuất các hướng phát triển tiếp theo để nâng cao hiệu quả của công nghệ này trong thực tế lâm sàng.

Quá trình nghiên cứu bắt đầu với việc khảo sát các phương pháp thị giác máy tính nói chung để có cái nhìn tổng quan về lĩnh vực này. Tiếp theo, chúng tôi tập trung vào các phương pháp thị giác máy tính trong phân tích ảnh y khoa, nhằm hiểu rõ hơn về các kỹ thuật phù hợp với bài toán phân đoạn hình ảnh y khoa.

Sau đó, công việc thu thập và xử lý dữ liệu ảnh siêu âm được tiến hành để làm cơ sở cho các bước tiếp theo. Tiếp theo, chúng tôi xây dựng phương pháp phân đoạn ảnh siêu âm theo hướng bán giám sát, nhằm giảm sự phụ thuộc vào dữ liệu có gán nhãn mà vẫn đảm bảo độ chính xác cao.

Khi phương pháp đã được xây dựng, chúng tôi thực hiện chạy mô hình và đánh giá kết quả phân đoạn ảnh siêu âm theo phương pháp đề xuất. Sau khi thu được

kết quả, chúng tôi tiến hành viết báo cáo về phương pháp phân đoạn ảnh siêu âm, phân tích ưu điểm và nhược điểm của mô hình.

Tiếp theo, chúng tôi tập trung khảo sát các cách khắc phục điểm yếu của phương pháp đã đề xuất để cải thiện độ chính xác. Sau đó, công việc thu thập thêm dữ liệu được thực hiện nhằm hỗ trợ quá trình đánh giá và cải tiến mô hình.

Sau khi có những điều chỉnh cần thiết, chúng tôi tiếp tục chạy mô hình và đánh giá kết quả theo hướng đã khắc phục. Tiếp đó, báo cáo về phương pháp cải tiến được hoàn thiện để ghi nhận quá trình nghiên cứu và các kết quả đạt được.

Cuối cùng, chúng tôi thực hiện viết báo cáo tổng hợp toàn bộ quá trình thực hiện khóa luận, đảm bảo đầy đủ nội dung và kết quả nghiên cứu, hoàn thiện và chỉnh sửa khóa luận theo yêu cầu của giáo viên phản biện và giáo viên hướng dẫn được thực hiện.

2.4 Phạm vi của đề tài

- Đối tượng nghiên cứu: Mô hình học sâu và các thuật toán học ứng dụng trên các hình ảnh y khoa dưới dạng hai chiều.
- Nguồn dữ liệu: Hình ảnh y khoa từ các phương thức chẩn đoán hình ảnh phổ biến như MRI, CT-Scan, Ultrasound. Các bộ dữ liệu này có thể được thu thập từ các nguồn công khai, bệnh viện hoặc phòng thí nghiệm nghiên cứu.
- Phương pháp tiếp cận: Ứng dụng các mô hình học sâu tiên tiến để phân đoạn hình ảnh y khoa. Sử dụng các phương pháp kết hợp dữ liệu có gán nhãn và không gán nhãn để tối ưu quá trình huấn luyện mô hình phân đoạn ảnh y khoa.
- Giới hạn nghiên cứu: Chỉ tập trung vào việc nhận diện và phân đoạn trên một số loại hình ảnh nhất định. Không đi sâu vào các vấn đề khác như phân tích gen, y học phân tử hoặc mô phỏng 3D cấu trúc sinh học.

2.5 Cách tiếp cận dự kiến

- Lựa chọn mô hình học sâu phù hợp: Phân tích và so sánh các mô hình phân đoạn ảnh phổ biến, đánh giá các phương pháp đã được áp dụng.
- Xây dựng pipeline tiền xử lý dữ liệu để cải thiện chất lượng ảnh siêu âm đầu vào, bao gồm các kỹ thuật như tăng cường dữ liệu (augmentation), làm mịn ảnh, loại bỏ nhiễu và chuẩn hóa kích thước.
- Đề xuất và triển khai các phương pháp học bán giám sát và học chủ động để khai thác tối đa thông tin từ tập dữ liệu hạn chế.
- Đánh giá mô hình dựa trên các chỉ số định lượng như Dice-Sørensen Coefficient, Jaccard Coefficient - JC, Hausdorff Distance - HD, Average Surface Distance - ASD và phân tích định tính thông qua hình ảnh trực quan.
- Đề xuất hướng cải tiến cho mô hình để nâng cao độ chính xác và khả năng tổng quát hóa khi áp dụng cho các bộ dữ liệu khác nhau.

2.6 Kết quả dự kiến của đề tài

Hệ thống sẽ sử dụng các mô hình học sâu nnUNet [8] để phân loại hình ảnh y khoa, phát hiện bất thường và khoanh vùng khu vực quan trọng. Mô hình sẽ được huấn luyện và thử nghiệm trên các bộ dữ liệu tiêu chuẩn trong y khoa, với mục tiêu đạt độ chính xác cao trong nhận diện bệnh lý. Các tiêu chí đánh giá đảm bảo mô hình có thể hoạt động hiệu quả trong thực tế lâm sàng.

Một trong những thách thức lớn của các mô hình học sâu là yêu cầu lượng lớn dữ liệu có gán nhãn để huấn luyện. Đề tài sẽ nghiên cứu các phương pháp học bán giám sát (semi-supervised learning) và học không giám sát (unsupervised learning) nhằm giảm thiểu sự phụ thuộc vào dữ liệu có gán nhãn, từ đó tăng tính ứng dụng của hệ thống vào các tình huống thực tế, nơi dữ liệu có gán nhãn thường khan hiếm hoặc khó thu thập.

Để đánh giá mức độ cải thiện của hệ thống, kết quả thu được sẽ được so sánh với các phương pháp hiện có trong lĩnh vực phân tích hình ảnh y khoa. Việc so sánh này sẽ giúp xác định những điểm mạnh, hạn chế của mô hình đề xuất, đồng thời đề xuất các hướng phát triển tiếp theo nhằm tối ưu hóa hiệu suất.

2.7 Kế hoạch thực hiện

Thời gian	Công việc
Ngày 01-15/01/2025	Khảo sát các phương pháp thị giác máy tính nói chung
Ngày 16-31/01/2025	Khảo sát các phương pháp thị giác máy tính trong phân tích ảnh y khoa
Ngày 01-15/02/2025	Thu thập và xử lý ảnh siêu âm
Ngày 16-28/02/2025	Xây dựng phương pháp phân đoạn ảnh siêu âm theo hướng bán giám sát
Ngày 01-15/03/2025	Chạy và khảo sát kết quả phân đoạn ảnh siêu âm theo hướng bán giám sát
Ngày 16-31/03/2025	Viết báo cáo về phân đoạn ảnh siêu âm
Ngày 01-15/04/2025	Khảo sát cách khắc phục điểm yếu của phương pháp
Ngày 16-30/04/2025	Thu thập thêm dữ liệu
Ngày 01-15/05/2025	Chạy và khảo sát kết quả theo hướng đã khắc phục
Ngày 16-31/05/2025	Viết báo cáo về phương pháp đã được cải tiến
Ngày 01-30/06/2025	Viết báo cáo tổng hợp về quá trình thực hiện khoá luận
Ngày 01-31/07/2025	Hoàn chỉnh và sửa đổi khoá luận theo yêu cầu của giáo viên phản biện và giáo viên hướng dẫn

Tài liệu


- [1] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015* (N. Navab, J. Hornegger, W. M. Wells, and A. F. Frangi, eds.), (Cham), pp. 234–241, Springer International Publishing, 2015.
- [2] O. Oktay, J. Schlemper, L. L. Folgoc, M. Lee, M. Heinrich, K. Misawa, K. Mori, S. McDonagh, N. Y. Hammerla, B. Kainz, B. Glocker, and D. Rueckert, “Attention u-net: Learning where to look for the pancreas,” in *Medical Imaging with Deep Learning*, 2018.
- [3] Ö. Çiçek, A. Abdulkadir, S. S. Lienkamp, T. Brox, and O. Ronneberger, “3d u-net: learning dense volumetric segmentation from sparse annotation,” in *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2016: 19th International Conference, Athens, Greece, October 17-21, 2016, Proceedings, Part II 19*, pp. 424–432, Springer, 2016.
- [4] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, Ł. Kaiser, and I. Polosukhin, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [5] A. Dosovitskiy, L. Beyer, A. Kolesnikov, D. Weissenborn, X. Zhai, T. Unterthiner, M. Dehghani, M. Minderer, G. Heigold, S. Gelly, J. Uszkoreit, and N. Houlsby, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021.
- [6] J. Chen, J. Mei, X. Li, Y. Lu, Q. Yu, Q. Wei, X. Luo, Y. Xie, E. Adeli, Y. Wang, *et al.*, “Transunet: Rethinking the u-net architecture design for medical image segmentation through the lens of transformers,” *Medical Image Analysis*, vol. 97, p. 103280, 2024.

- [7] A. Hatamizadeh, Y. Tang, V. Nath, D. Yang, A. Myronenko, B. Landman, H. R. Roth, and D. Xu, “Unetr: Transformers for 3d medical image segmentation,” in *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pp. 574–584, 2022.
- [8] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen, and K. H. Maier-Hein, “nnu-net: a self-configuring method for deep learning-based biomedical image segmentation,” *Nature Methods*, vol. 18, pp. 203–211, Feb 2021.
- [9] X. Wu, L. Xiao, Y. Sun, J. Zhang, T. Ma, and L. He, “A survey of human-in-the-loop for machine learning,” *Future Generation Computer Systems*, vol. 135, p. 364–381, Oct. 2022.
- [10] J. Zhu and J. Wu, “Meduhip: Towards human-in-the-loop medical segmentation,” 2024.
- [11] H. Li, B. Oguz, G. Arenas, X. Yao, J. Wang, D. Lu, A. Pouch, B. Byram, N. Schwartz, and I. Oguz, “Prism lite: A lightweight model for interactive 3d placenta segmentation in ultrasound,” in *Medical Imaging 2025: Image Processing*, vol. 13406, pp. 65–70, SPIE, 2025.
- [12] D. Li, Z. Wang, Y. Chen, R. Jiang, W. Ding, and M. Okumura, “A survey on deep active learning: Recent advances and new frontiers,” *IEEE Transactions on Neural Networks and Learning Systems*, 2024.
- [13] Z. Zhou, M. M. Rahman Siddiquee, N. Tajbakhsh, and J. Liang, “Unet++: A nested u-net architecture for medical image segmentation,” in *Deep learning in medical image analysis and multimodal learning for clinical decision support: 4th international workshop, DLMIA 2018, and 8th international workshop, ML-CDS 2018, held in conjunction with MICCAI 2018, Granada, Spain, September 20, 2018, proceedings 4*, pp. 3–11, Springer, 2018.

- [14] H. Cao, Y. Wang, J. Chen, D. Jiang, X. Zhang, Q. Tian, and M. Wang, “Swin-unet: Unet-like pure transformer for medical image segmentation,” in *European conference on computer vision*, pp. 205–218, Springer, 2022.
- [15] A. Hatamizadeh, V. Nath, Y. Tang, D. Yang, H. R. Roth, and D. Xu, “Swin unetr: Swin transformers for semantic segmentation of brain tumors in mri images,” in *International MICCAI brainlesion workshop*, pp. 272–284, Springer, 2021.
- [16] J. Qiu, F. Wilm, M. Öttl, M. Schlereth, C. Liu, T. Heimann, M. Aubreville, and K. Breininger, “Adaptive region selection for active learning in whole slide image semantic segmentation,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023* (H. Greenspan, A. Madabhushi, P. Mousavi, S. Salcudean, J. Duncan, T. Syeda-Mahmood, and R. Taylor, eds.), (Cham), pp. 90–100, Springer Nature Switzerland, 2023.
- [17] Y. Tang, Y. Hu, J. Li, H. Lin, X. Xu, K. Huang, and H. Lin, “Pld-al: Pseudo-label divergence-based active learning in carotid intima-media segmentation for ultrasound images,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023* (H. Greenspan, A. Madabhushi, P. Mousavi, S. Salcudean, J. Duncan, T. Syeda-Mahmood, and R. Taylor, eds.), (Cham), pp. 57–67, Springer Nature Switzerland, 2023.
- [18] S. Balaram, C. M. Nguyen, A. Kassim, and P. Krishnaswamy, “Consistency-based semi-supervised evidential active learning for diagnostic radiograph classification,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022* (L. Wang, Q. Dou, P. T. Fletcher, S. Speidel, and S. Li, eds.), (Cham), pp. 675–685, Springer Nature Switzerland, 2022.
- [19] F. Milletari, N. Navab, and S.-A. Ahmadi, “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 fourth international conference on 3D vision (3DV)*, pp. 565–571, Ieee, 2016.

XÁC NHẬN
CỦA NGƯỜI HƯỚNG DẪN
(Ký và ghi rõ họ tên)

TP. Hồ Chí Minh, ngày 02 tháng 04 năm 2025
NHÓM SINH VIÊN THỰC HIỆN
(Ký và ghi rõ họ tên)


Trần Nam Khánh


Phan Lê Đức Phú

Mục lục

Lời cảm ơn	ii
Đề cương	iii
Mục lục	xvi
Danh sách hình	xix
Danh sách bảng	xx
Tóm tắt	xx
1 Giới thiệu	1
1.1 Lý do chọn đề tài	1
1.2 Mục đích nghiên cứu	2
1.3 Đối tượng nghiên cứu	3
1.4 Phạm vi nghiên cứu	4
1.5 Đóng góp của đề tài	5
2 Các công trình liên quan	10
2.1 Học sâu	10
2.1.1 Học sâu nói chung	10
2.1.2 Học sâu với hình ảnh	13
2.1.3 Học sâu trong y khoa	16
2.1.4 Phân đoạn ảnh y khoa	18

2.2	Human-in-the-loop và Học sâu chủ động	21
2.2.1	Human-in-the-Loop	21
2.2.2	Học sâu chủ động	22
2.3	Mô hình cơ sở	24
2.3.1	Mô hình ảnh tự nhiên	24
2.3.2	Mô hình ảnh y khoa	27
2.4	Pipelines xử lý dữ liệu và đánh giá mô hình	29
2.4.1	Tiền xử lý dữ liệu	29
2.4.2	Hậu xử lý dữ liệu	30
2.4.3	Đánh giá mô hình	30
3	Phương pháp đề xuất	32
3.1	Ký hiệu	32
3.2	Huấn luyện mô hình	34
3.2.1	Kiến trúc mô hình	34
3.2.2	Hàm mục tiêu	34
3.3	Chọn lựa mẫu	35
3.3.1	Tích hợp đặc trưng nền tảng	35
3.3.2	Hàm chọn	39
3.4	Vòng lặp học chủ động	40
3.5	Hậu xử lý đầu ra	41
4	Thí nghiệm và kết quả	43
4.1	Các bộ dữ liệu	43
4.2	Các chi tiết về cài đặt	46
4.3	Thang đo	47
4.4	Kết quả định lượng	48
4.5	Kết quả định tính	55
4.6	Sự ảnh hưởng của các thành phần	59
4.7	Mô phỏng đặc trưng	65
5	Kết luận	68

Danh mục công trình của tác giả	70
Tài liệu tham khảo	71

Danh sách hình

3.1	Quy trình tổng quát của phương pháp học chủ động	33
3.2	Phương pháp chọn mẫu chủ động	36
3.3	Hậu xử lý đầu ra	41
4.1	Ví dụ về các mẫu dữ liệu trong bộ dữ liệu FUGC2025	44
4.2	Ví dụ về các mẫu dữ liệu trong bộ dữ liệu BUSI	45
4.3	Các phương pháp tăng cường dữ liệu	46
4.4	Kết quả định lượng trên bộ dữ liệu FUGC2025 ($b = 5$)	49
4.5	Kết quả định lượng trên bộ dữ liệu FUGC2025 ($b = 10$)	50
4.6	Kết quả định lượng trên bộ dữ liệu BUSI	54
4.7	Kết quả định tính trên bộ dữ liệu FUGC2025	56
4.8	Kết quả định tính trên bộ dữ liệu BUSI	57
4.9	Các đặc trưng mô phỏng bằng thuật toán t-SNE.	66

Danh sách bảng

4.1	Top 5 team trên bảng xếp hạng được công bố trên codabench của cuộc thi FUGC 2025 (xếp theo DSC). Kết quả của đội chúng tôi được in đậm trong bảng.	48
4.2	Sự ảnh hưởng của các mô hình nền tảng $\mathcal{M}_f$ và sự hiện diện của mô hình chuyên môn $\mathcal{M}_s$ đến độ hiệu quả của quy trình học chủ động.	60
4.3	Sự ảnh hưởng của trọng số đặc trưng nền tảng s đến độ hiệu quả của phương pháp. Ở đây, chúng tôi thử nghiệm với 5 giá trị δ khác nhau: 0.5, 1.0, 2.0, 8.0, 32.0 với ngân sách mẫu $b = 10$ và tham số làm nhọn $\beta = 1.0$.	61
4.4	Sự ảnh hưởng của hàm chuẩn hoá $g(\cdot)$ và tham số làm nhọn β đến độ hiệu quả của quy trình học chủ động.	62

Tóm tắt

Trong bối cảnh ngành y tế đang đối mặt với áp lực ngày càng gia tăng về khối lượng công việc và nhu cầu nâng cao chất lượng chẩn đoán, việc ứng dụng trí tuệ nhân tạo, đặc biệt là học sâu, vào phân tích ảnh y khoa trở thành hướng nghiên cứu tiềm năng và cần thiết. Đặc biệt, ảnh siêu âm - tuy phổ biến và dễ tiếp cận - lại thường có chất lượng thấp, nhiễu mạnh và khó gán nhãn chính xác, khiến cho bài toán phân đoạn trở nên phức tạp trong điều kiện dữ liệu hạn chế.

Đề tài này hướng đến việc xây dựng một mô hình học sâu với sự hỗ trợ của các phương pháp học chủ động nhằm phân đoạn chính xác ảnh siêu âm y khoa với chi phí gán nhãn tối thiểu.

Phương pháp đề xuất bao gồm thiết kế pipeline xử lý dữ liệu hoàn chỉnh, ứng dụng kiến trúc UNet cải tiến trong mô hình học sâu, kết hợp kỹ thuật bán giám sát như gán nhãn giả (pseudo-labeling) với học chủ động (active learning) nhằm chọn lọc tối ưu các mẫu dữ liệu cần gán nhãn. Mô hình được huấn luyện và đánh giá trên tập dữ liệu ảnh siêu âm thực tế, với các chỉ số định lượng như hệ số Dice-Sørensen và khoảng cách Hausdorff.

Đề tài cho thấy tiềm năng của việc kết hợp học sâu và học chủ động trong xử lý ảnh y khoa, đồng thời mở ra hướng ứng dụng thực tiễn trong các hệ thống hỗ trợ chẩn đoán thông minh, góp phần thúc đẩy chuyển đổi số ngành y tế và nâng cao chất lượng chăm sóc sức khỏe.

Chương 1

Giới thiệu

1.1 Lý do chọn đề tài

Trong kỷ nguyên số hiện đại, dữ liệu đang trở thành tài nguyên có giá trị hàng đầu, đặc biệt trong lĩnh vực y tế - nơi mà mỗi quyết định chẩn đoán và điều trị đều phụ thuộc vào khả năng khai thác, phân tích và hiểu đúng dữ liệu. Trong đó, dữ liệu hình ảnh y khoa chiếm một tỷ trọng đáng kể, với sự phổ biến của các kỹ thuật chẩn đoán hình ảnh như cộng hưởng từ (MRI), chụp cắt lớp (CT-Scan), X-quang và siêu âm (Ultrasound). Trong số đó, siêu âm là một trong những kỹ thuật phổ biến nhất vì tính linh hoạt, chi phí thấp và không gây hại đến sức khỏe người bệnh.

Tuy nhiên, đặc điểm của ảnh siêu âm là thường bị nhiễu (speckle noise), độ tương phản thấp, phụ thuộc nhiều vào kỹ năng người vận hành thiết bị, và khó khăn trong việc xác định ranh giới giữa các mô mềm. Điều này đặt ra thách thức lớn cho quá trình chẩn đoán bằng mắt thường hoặc phụ thuộc hoàn toàn vào kinh nghiệm của bác sĩ. Đặc biệt trong các bệnh lý như ung thư gan, ung thư vú, ... hay các bất thường sản khoa thì việc phát hiện sớm và chính xác qua ảnh siêu âm có ý nghĩa sống còn.

Đứng trước những thách thức này, trí tuệ nhân tạo, đặc biệt là các mô hình học sâu, đã mở ra một hướng đi mới trong việc phân tích ảnh y khoa. Với khả năng chọn lọc và học trực tiếp từ dữ liệu, tự động phát hiện và

trích xuất đặc trưng có ý nghĩa, mô hình học sâu giúp cải thiện đáng kể hiệu suất trong các bài toán như phân loại, phát hiện và đặc biệt là phân đoạn hình ảnh. Phân đoạn ảnh - quá trình xác định chính xác vị trí và ranh giới của các cấu trúc sinh học - là bước tiền đề quan trọng cho nhiều tác vụ tiếp theo như định lượng kích thước khối u, mô phỏng điều trị, và theo dõi tiến triển bệnh.

Dù vậy, để huấn luyện được một mô hình chính xác, việc thu thập dữ liệu ảnh và gán nhãn là yếu tố then chốt, nhưng cũng là rào cản lớn trong y tế. Việc gán nhãn đòi hỏi chuyên môn cao, mất nhiều thời gian và công sức của các chuyên gia y tế. Do đó, hướng tiếp cận bán giám sát (semi-supervised learning) và học chủ động (active learning), nơi chỉ cần một phần dữ liệu được gán nhãn, trong khi phần còn lại được tận dụng nhờ vào các kỹ thuật học không giám sát và tăng cường dữ liệu, đang là xu hướng nghiên cứu được quan tâm bởi vì tính hiệu quả của nó đối với những bài toán ít dữ liệu đặc thù trong y khoa.

Chính từ những vấn đề thực tiễn, tiềm năng công nghệ, và nhu cầu cấp thiết trong y tế hiện nay, đề tài “Ứng dụng thị giác máy tính hỗ trợ chẩn đoán hình ảnh y khoa” được lựa chọn để nghiên cứu và phát triển trong khuôn khổ khóa luận tốt nghiệp. Đề tài không chỉ mang tính học thuật mà còn định hướng giải quyết một bài toán thực tế có ảnh hưởng rộng lớn tới công tác khám chữa bệnh, đặc biệt trong bối cảnh chuyển đổi số đang diễn ra mạnh mẽ trong ngành y tế Việt Nam.

1.2 Mục đích nghiên cứu

Mục tiêu của đề tài là xây dựng một mô hình học sâu có khả năng phân đoạn chính xác các vùng quan tâm trên ảnh siêu âm y khoa, đồng thời giảm thiểu sự phụ thuộc vào dữ liệu được gán nhãn. Cụ thể, bên dưới đây là những mục tiêu cốt lõi mà đề tài hướng đến:

- Lựa chọn mô hình học sâu phù hợp: Phân tích và so sánh các mô

hình phân đoạn ảnh phổ biến, đánh giá các phương pháp đã được áp dụng.

- Xây dựng pipeline tiền xử lý dữ liệu để cải thiện chất lượng ảnh siêu âm đầu vào, bao gồm các kỹ thuật như tăng cường dữ liệu (augmentation), làm mịn ảnh, loại bỏ nhiễu và chuẩn hóa kích thước.
- Đề xuất và triển khai các phương pháp học bán giám sát và học chủ động để khai thác tối đa thông tin từ tập dữ liệu hạn chế.
- Đánh giá mô hình dựa trên các chỉ số định lượng như Dice-Sørensen Coefficient, Jaccard Coefficient - JC, Hausdorff Distance - HD, Average Surface Distance - ASD và phân tích định tính thông qua hình ảnh trực quan.
- Đề xuất hướng cải tiến cho mô hình để nâng cao độ chính xác và khả năng tổng quát hóa khi áp dụng cho các bộ dữ liệu khác nhau.

Ngoài ra, nghiên cứu của đề tài không chỉ dừng lại ở việc đạt được kết quả tốt về mặt số liệu, mà sâu xa hơn nữa còn hướng đến xây dựng nền tảng, tích hợp phần mềm cho các hệ thống chẩn đoán thông minh, hỗ trợ bác sĩ trong việc ra quyết định, đặc biệt trong các tình huống khó khăn hoặc thiếu chuyên môn chuyên sâu.

1.3 Đối tượng nghiên cứu

Đối tượng nghiên cứu của đề tài bao gồm các thành phần cốt lõi phục vụ cho việc xây dựng và đánh giá mô hình học sâu trong bài toán phân đoạn ảnh siêu âm y khoa. Trước hết, dữ liệu đầu vào là các ảnh siêu âm hai chiều (2D ultrasound) được thu thập từ các nguồn công khai, với một phần dữ liệu đã được gán nhãn sẵn bằng mặt nạ (mask). Đây là loại dữ liệu có tính thực tiễn cao, thường gặp trong lâm sàng, nhưng cũng đặt ra

nhiều thách thức do nhiễu, chất lượng hình ảnh không đồng đều và thiếu nhất quán trong cấu trúc giải phẫu.

Về mặt mô hình, đề tài nghiên cứu và áp dụng các kiến trúc mạng nơ-ron tích chập (CNN) hiện đại - những kiến trúc đã được chứng minh hiệu quả trong nhiều tác vụ phân đoạn y khoa. Các kỹ thuật hỗ trợ như chuẩn hóa (batch normalization), làm mịn ảnh, loại bỏ nhiễu và tăng cường dữ liệu (data augmentation) được tích hợp nhằm tăng tính ổn định và khả năng tổng quát của mô hình trong quá trình huấn luyện.

Về công cụ và nền tảng, đề tài sử dụng các framework phổ biến trong cộng đồng nghiên cứu như PyTorch, Tensorflow để xây dựng và huấn luyện mô hình. Bên cạnh đó, các thư viện như OpenCV, scikit-learn hay các công cụ hỗ trợ gán nhãn như Label Studio cũng được sử dụng để xử lý hình ảnh, tiền xử lý dữ liệu và đánh giá hiệu suất. Việc lựa chọn các công cụ này góp phần đảm bảo tính khả thi, dễ mở rộng và dễ tích hợp trong các hệ thống ứng dụng thực tế vì tính tương thích của chúng và sự thông dụng của chúng.

1.4 Phạm vi nghiên cứu

Phạm vi nghiên cứu của đề tài được xác lập một cách cụ thể và có chủ đích nhằm đảm bảo tính khả thi trong khuôn khổ thời gian, nhân lực và tài nguyên sẵn có của quá trình thực hiện khóa luận. Việc giới hạn phạm vi giúp chúng tôi nghiên cứu tập trung sâu vào một bài toán trọng tâm, tránh dàn trải nguồn lực, đồng thời đảm bảo chất lượng và độ sâu của các phân tích kỹ thuật.

Về mặt dữ liệu, đề tài chỉ tập trung xử lý và phân đoạn ảnh siêu âm hai chiều (2D ultrasound). Đây là loại ảnh phổ biến nhất trong thực hành lâm sàng nhờ chi phí thấp, không xâm lấn và dễ triển khai. Tuy nhiên, ảnh siêu âm 2D lại có chất lượng không cao, nhiễu nhiều và phụ thuộc lớn vào người vận hành, dẫn đến những khó khăn đặc thù trong phân tích bằng mô hình học máy. Việc lựa chọn giới hạn này nhằm khai thác tối đa

hiệu quả mô hình trong điều kiện thực tế thường gặp, đồng thời chưa mở rộng sang các loại ảnh phức tạp hơn như ảnh ba chiều (3D), ảnh Doppler hay ảnh siêu âm động (video), do yêu cầu về dữ liệu, thiết bị và khả năng xử lý cao hơn.

Về mặt kỹ thuật, đề tài tập trung ứng dụng học sâu, cụ thể là các phương pháp học bán giám sát kết hợp với học chủ động. Đây là hướng tiếp cận phù hợp với bối cảnh dữ liệu y khoa thường thiếu nhãn và đắt đỏ trong quá trình gán nhãn. Các kỹ thuật khác điển hình như học tăng cường (reinforcement learning), học có đối kháng (GANs), hoặc học liên kết (federated learning) tuy có nhiều tiềm năng, nhưng yêu cầu hệ thống phức tạp và thời gian nghiên cứu dài hơn nên không nằm trong phạm vi nghiên cứu của đề tài.

Về bài toán được lựa chọn, chúng tôi chỉ tập trung vào bài toán phân đoạn ảnh - một nhánh công việc có vai trò quan trọng trong hỗ trợ chẩn đoán, giúp xác định chính xác vị trí và hình dạng của các cấu trúc hoặc tổn thương trong ảnh siêu âm. Các bài toán khác như phân loại bệnh lý hay phát hiện bất thường (object detection) tuy có liên quan nhưng không phải là mục tiêu chính của nghiên cứu này.

Cuối cùng, về mặt ứng dụng, đề tài hướng đến xây dựng một mô hình nguyên mẫu (prototype) nhằm kiểm chứng tính hiệu quả của phương pháp được đề xuất. Mô hình được thiết kế để phục vụ mục đích nghiên cứu và trình diễn trong môi trường giả lập, chưa triển khai trong các môi trường lâm sàng thực tế. Tuy nhiên, kết quả nghiên cứu có thể làm nền tảng cho các phát triển trong tương lai nếu được mở rộng và tích hợp vào hệ thống chẩn đoán y tế thông minh.

1.5 Đóng góp của đề tài

Đề tài mang lại nhiều đóng góp quan trọng trên cả phương diện học thuật, kỹ thuật và thực tiễn, phản ánh qua cách tiếp cận bài bản, sự lựa chọn phương pháp phù hợp với điều kiện thực tế, cũng như tiềm năng ứng

dụng trong lĩnh vực y tế. Những đóng góp này không chỉ thể hiện ở kết quả đạt được trong khuôn khổ đề tài mà còn mở ra các hướng phát triển cho nghiên cứu chuyên sâu trong tương lai.

Đóng góp học thuật

Về mặt học thuật, đề tài đã có những đóng góp đáng kể thông qua việc tổng hợp, phân tích và hệ thống hóa các phương pháp học sâu được ứng dụng trong phân đoạn ảnh siêu âm y khoa. Việc này không chỉ giúp người đọc có cái nhìn toàn diện về các hướng tiếp cận hiện có mà còn tạo tiền đề cho các sự phát triển hay nghiên cứu chuyên sâu hơn trong tương lai.

Một đóng góp nổi bật khác là đề xuất phương pháp học chủ động phù hợp với bối cảnh thực tế của ngành y tế, nơi dữ liệu được gán nhãn thường rất ít do yêu cầu chuyên môn cao và thời gian gán nhãn tốn kém. Việc lựa chọn và triển khai phương pháp bán giám sát giúp tiết kiệm nguồn lực trong quá trình xây dựng mô hình, đồng thời vẫn đảm bảo chất lượng phân đoạn đáng tin cậy, mở ra khả năng áp dụng rộng rãi hơn trong thực tế.

Bên cạnh đó, đề tài cũng tập trung làm rõ vai trò và ảnh hưởng của từng yếu tố trong toàn bộ pipeline huấn luyện - từ khâu xử lý dữ liệu, lựa chọn kiến trúc mô hình, đến chiến lược huấn luyện và đánh giá. Việc phân tích chi tiết từng thành phần giúp xác định những điểm then chốt ảnh hưởng đến hiệu suất của mô hình, từ đó đề xuất hướng điều chỉnh hoặc cải tiến phù hợp. Đây là cơ sở quan trọng giúp nâng cao chất lượng nghiên cứu và đóng góp vào sự phát triển chung của cộng đồng học thuật trong lĩnh vực học sâu và xử lý ảnh y khoa.

Đóng góp kỹ thuật

Những đóng góp về mặt kỹ thuật của đề tài được thể hiện rõ ràng trong quá trình xây dựng và triển khai một hệ thống huấn luyện mô hình học sâu hoàn chỉnh. Hệ thống này bao gồm đầy đủ các bước từ xử lý dữ liệu

đầu vào - tiền xử lý ảnh siêu âm, thiết kế và huấn luyện mô hình, cho đến đánh giá kết quả bằng các chỉ số định lượng và trực quan hóa. Mỗi thành phần trong pipeline đều được xây dựng một cách tường minh, có tính hệ thống cao, nhằm đảm bảo tính ổn định và khả năng tái lập kết quả trong các lần thử nghiệm khác nhau.

Ngoài ra, đề tài còn cung cấp đầy đủ mã nguồn kèm theo hướng dẫn sử dụng chi tiết, giúp các nhà nghiên cứu hoặc kỹ sư trong lĩnh vực dễ dàng tiếp cận, kiểm thử và mở rộng mô hình theo nhu cầu riêng. Đây là một điểm mạnh quan trọng, bởi trong nghiên cứu khoa học, việc chia sẻ mã nguồn và quy trình thực hiện không chỉ tăng tính minh bạch mà còn thúc đẩy cộng đồng phát triển những giải pháp tốt hơn dựa trên nền tảng đã có.

Không dừng lại ở việc trình bày kết quả mô hình, đề tài còn chủ động đề xuất các hướng cải tiến dựa trên quá trình đánh giá thực nghiệm. Thông qua việc phân tích các trường hợp mô hình hoạt động chưa tốt, chúng tôi đã rút ra được một số hạn chế và đề xuất các chiến lược nâng cao, chẳng hạn như thử nghiệm các kiến trúc mạng mới, cải thiện kỹ thuật tiền xử lý hoặc áp dụng các phương pháp huấn luyện tiên tiến hơn. Cụ thể tiêu biểu nhất trong đề tài là huấn luyện chủ động - phương pháp sẽ được đề cập ở những phần tiếp theo. Những đề xuất này là tiền đề quan trọng cho các nghiên cứu tiếp theo nhằm tối ưu hóa hiệu suất của mô hình trong điều kiện thực tế.

Đóng góp thực tiễn

Những đóng góp thực tiễn của đề tài thể hiện rõ qua khả năng ứng dụng trực tiếp vào hoạt động khám chữa bệnh tại các cơ sở y tế. Mô hình phân đoạn ảnh siêu âm được phát triển có tiềm năng tích hợp vào các phần mềm hỗ trợ chẩn đoán, giúp bác sĩ dễ dàng xác định các vùng tổn thương hoặc cấu trúc quan trọng trên ảnh y khoa. Điều này đặc biệt hữu ích tại các tuyến y tế cơ sở, nơi nguồn lực còn hạn chế và thiếu hụt bác sĩ chuyên

khoa là vấn đề phổ biến.

Bên cạnh đó, việc áp dụng hệ thống chẩn đoán hỗ trợ bằng máy học giúp nâng cao hiệu suất làm việc của đội ngũ y tế. Thay vì phải thực hiện thủ công từng bước trong quá trình phân tích hình ảnh, bác sĩ có thể sử dụng công cụ hỗ trợ để nhanh chóng đưa ra nhận định ban đầu, từ đó tiết kiệm thời gian và giảm thiểu khả năng sai sót - đặc biệt trong bối cảnh áp lực công việc ngày càng lớn tại các bệnh viện.

Ngoài lợi những ích trước mắt, đề tài còn góp phần thúc đẩy việc đưa trí tuệ nhân tạo vào ngành y tế, phù hợp với chủ trương chuyển đổi số quốc gia nói riêng hay xu hướng phát triển của xã hội nói chung. Việc phát triển và thử nghiệm các giải pháp công nghệ như vậy không chỉ hỗ trợ trực tiếp cho công tác chuyên môn mà còn đóng vai trò quan trọng trong xây dựng hệ sinh thái y tế thông minh hướng đến một nền y tế hiện đại, chính xác và dễ tiếp cận hơn cho mọi người dân.

Khả năng mở rộng

Đề tài không chỉ dừng lại ở việc giải quyết một bài toán cụ thể mà còn mở ra nhiều hướng phát triển tiềm năng trong tương lai. Mô hình học sâu được xây dựng có tính linh hoạt cao và hoàn toàn có thể không chỉ tập trung vào mỗi ảnh siêu âm (2D) như trong đề tài mà còn có thể mở rộng để áp dụng cho các loại ảnh y khoa khác như MRI, CT-Scan hoặc ảnh ba chiều (3D), vốn mang lại nhiều thông tin chi tiết hơn trong việc phân tích cấu trúc giải phẫu. Việc mở rộng này cho phép ứng dụng mô hình mới trong các lĩnh vực chuyên sâu hơn như thần kinh, ung bướu, tim mạch, góp phần nâng cao hiệu quả chẩn đoán trong đa dạng bệnh lý.

Bên cạnh đó, kết quả và quy trình nghiên cứu từ đề tài có thể được sử dụng như một nền tảng vững chắc cho các đề tài nghiên cứu tiếp theo trong lĩnh vực y học thông minh (smart healthcare). Những cải tiến về mặt kỹ thuật, cùng với kinh nghiệm triển khai thực tế, sẽ giúp rút ngắn thời gian phát triển cho các dự án sau này, đồng thời tăng độ tin cậy của

các mô hình khi ứng dụng trong môi trường lâm sàng.

Hơn nữa, hệ thống được phát triển có thể tích hợp với các nền tảng công nghệ hiện đại như hệ thống bệnh án điện tử (EMR - Electronic Medical Records) hoặc các thiết bị chẩn đoán tiên tiến, nhằm tự động hóa quy trình lưu trữ, phân tích và đánh giá kết quả hình ảnh y khoa. Điều này không chỉ giúp đồng bộ hóa dữ liệu trong quá trình điều trị mà còn hỗ trợ xây dựng hệ thống y tế thông minh, nơi mọi dữ liệu chẩn đoán và điều trị đều được khai thác một cách tối ưu để phục vụ người bệnh.

Chương 2

Các công trình liên quan

2.1 Học sâu

2.1.1 Học sâu nói chung

Học sâu (Deep Learning) là một nhánh quan trọng của học máy (Machine Learning), được xây dựng dựa trên mạng nơ-ron nhiều lớp. Với khả năng tự động trích xuất đặc trưng từ dữ liệu thô thông qua các tầng phi tuyến liên tiếp, học sâu đã trở thành công cụ cốt lõi trong nhiều đột phá gần đây của trí tuệ nhân tạo (AI). Thay vì phụ thuộc vào các kỹ thuật trích chọn đặc trưng thủ công truyền thống, các mô hình học sâu có thể học trực tiếp biểu diễn dữ liệu tối ưu cho từng bài toán, từ đó cải thiện đáng kể hiệu suất trên nhiều tác vụ khác nhau.

Sự phổ biến của học sâu bắt đầu từ các thành công trong lĩnh vực thị giác máy tính và xử lý ngôn ngữ tự nhiên, sau đó nhanh chóng mở rộng ra nhiều lĩnh vực khác như phân tích chuỗi thời gian, chẩn đoán y tế, robot, tài chính, và hệ thống đề xuất. Trong lĩnh vực thị giác, học sâu đã làm thay đổi hoàn toàn cách tiếp cận các bài toán như nhận diện ảnh, phát hiện vật thể, phân đoạn ảnh, Trong xử lý ngôn ngữ tự nhiên, học sâu cho phép máy tính hiểu và sinh ngôn ngữ tự nhiên với độ chính xác và mạch lạc chưa từng có.

Trong quá trình phát triển của học sâu, nhiều kiến trúc mạng nơ-ron

đã được đề xuất nhằm giải quyết các loại dữ liệu và bài toán khác nhau, phản ánh sự thích nghi và mở rộng của công nghệ này trong nhiều lĩnh vực. Khi học sâu bắt đầu chứng minh ưu thế vượt trội trong thị giác máy tính, mạng nơ-ron tích chập (CNN) đã nổi lên như một kiến trúc nền tảng. CNN được thiết kế đặc biệt để xử lý dữ liệu có cấu trúc lưới, chẳng hạn như hình ảnh (một lưới hai chiều của các điểm ảnh). Thành phần chính làm nên sức mạnh của CNN là phép tích chập (convolution), một kỹ thuật cho phép mô hình tự động học được các đặc trưng không gian quan trọng như cạnh, góc, hình dạng... thông qua các bộ lọc (filters) di chuyển trên ảnh đầu vào. Mỗi bộ lọc học cách phản ứng với một mẫu đặc trưng nhất định và tạo ra bản đồ đặc trưng (feature map) thể hiện sự hiện diện của mẫu đó trong ảnh. Nhờ khả năng trích xuất đặc trưng hiệu quả và tái sử dụng tham số, CNN giúp giảm đáng kể số lượng tham số cần học so với mạng nơ-ron truyền thống, đồng thời nâng cao hiệu quả và độ chính xác trong các bài toán như phân loại ảnh, phát hiện vật thể, và nhận dạng khuôn mặt.

Tuy nhiên, khi học sâu được mở rộng sang xử lý dữ liệu tuần tự - chẳng hạn như văn bản, lời nói hay chuỗi tín hiệu sinh học - thì những giới hạn của CNN trong việc mô hình hóa quan hệ theo thời gian trở nên rõ ràng. Lúc này, mạng nơ-ron hồi tiếp (RNN) [1] được phát triển để học từ các chuỗi dữ liệu, trong đó đầu ra ở mỗi thời điểm phụ thuộc vào trạng thái trước đó. Nhờ khả năng ghi nhớ thông tin trong chuỗi, RNN đã đóng vai trò quan trọng trong các nhiệm vụ như dịch máy, phân tích cảm xúc, hoặc dự đoán chuỗi. Dù vậy, RNN truyền thống gặp nhiều thách thức khi xử lý các chuỗi dài, đặc biệt là hiện tượng tiêu biến gradient, khiến việc học phụ thuộc dài hạn trở nên khó khăn.

Chính những hạn chế này đã tạo tiền đề cho sự ra đời của Transformer [2] - một kiến trúc học sâu phi tuần tự dựa trên cơ chế tự chú ý (self-attention). Transformer không chỉ giải quyết triệt để bài toán phụ thuộc dài hạn trong chuỗi, mà còn cho phép mô hình học mối liên hệ toàn cục giữa các phần tử trong dữ liệu một cách linh hoạt và hiệu quả. Cơ chế tự

chú ý (self-attention) giúp mỗi phần tử trong đầu vào có thể tham chiếu đến mọi phần tử khác, bất kể vị trí, từ đó tăng cường khả năng nắm bắt ngữ cảnh tổng thể. Transformer nhanh chóng trở thành chuẩn mực trong xử lý ngôn ngữ tự nhiên, là nền tảng cho hàng loạt mô hình ngôn ngữ lớn hiện nay. Điển hình như BERT (Bidirectional Encoder Representations from Transformers) [3] là một trong những mô hình đầu tiên ứng dụng Transformer vào huấn luyện hai chiều trên văn bản, nhờ đó có thể hiểu sâu hơn ngữ nghĩa của ngữ cảnh. BERT [3] mở ra hướng huấn luyện trước - tinh chỉnh (pretraining - fine tuning) mà ngày nay đã trở thành tiêu chuẩn cho hầu hết các mô hình NLP hiện đại. Bên cạnh đó, dòng mô hình GPT (Generative Pretrained Transformer) [4] được thiết kế theo hướng sinh ngôn ngữ, tức là dự đoán từ tiếp theo dựa vào chuỗi các từ trước đó. Với kiến trúc decoder đơn hướng, GPT [4] thể hiện khả năng tạo văn bản tự nhiên trôi chảy, phù hợp với các ứng dụng như viết nội dung, chatbot, hay tổng hợp thông tin. Khả năng sinh và hiểu ngôn ngữ của GPT ngày càng tiến gần đến trình độ con người, đặc biệt khi được huấn luyện trên các kho dữ liệu lớn và đa dạng. Không dừng lại ở văn bản, kiến trúc này còn được mở rộng sang các miền dữ liệu khác như ảnh, âm thanh, và mô hình đa mô thức - nơi nó giúp kết nối các nguồn thông tin dị biệt một cách hài hòa.

Không những thế, học sâu đang đóng vai trò quan trọng trong các mô hình học sinh (generative models) [5] như GAN (Generative Adversarial Networks) [6], Diffusion Models [7], ... cho phép sinh dữ liệu mới - một yếu tố đặc biệt hữu ích trong các lĩnh vực thiếu dữ liệu gán nhãn như y tế. Những mô hình này không chỉ phục vụ mục tiêu tăng cường dữ liệu, mà còn giúp mô phỏng môi trường, tạo hình ảnh tổng hợp, hoặc xây dựng các hệ thống AI sáng tạo.

Sự phát triển của học sâu không thể tách rời với tiến bộ về hạ tầng tính toán (như GPU, TPU, ...), sự phong phú của dữ liệu và sự cải tiến trong thuật toán huấn luyện. Cùng với đó, các nền tảng mã nguồn mở như PyTorch, TensorFlow, hay nền tảng Hugging Face đã thúc đẩy mạnh

mẽ sự lan tỏa của học sâu trong cộng đồng nghiên cứu và ứng dụng công nghiệp. Học sâu không chỉ là một kỹ thuật mạnh, mà còn là nền tảng tri thức hiện đại cho các hệ thống AI thông minh, có khả năng học hỏi từ dữ liệu lớn, thích ứng với môi trường đa dạng và hỗ trợ ra quyết định trong những lĩnh vực có tính phức tạp và rủi ro cao như y học, luật pháp, và kỹ thuật tự động.

2.1.2 Học sâu với hình ảnh

Với lĩnh vực thị giác máy tính, mạng nơ-ron tích chập (CNN - Convolutional Neural Network) được xem là một nền tảng cốt lõi. Trong đó, ResNet (Residual Network) [8] là một bước đột phá trong việc huấn luyện mạng sâu, với cơ chế kết nối tắt (residual connection) cho phép huấn luyện các mạng lên đến hàng trăm lớp mà không gặp vấn đề tiêu biến gradient. Mạng ResNet không chỉ cải thiện độ chính xác mà còn làm đơn giản hóa quá trình thiết kế mô hình nhờ khả năng mở rộng tốt. Tiếp nối đó, EfficientNet [9] đề xuất một nguyên lý mở rộng mô hình có hệ thống gọi là compound scaling, giúp cân bằng giữa chiều sâu, chiều rộng và độ phân giải đầu vào để đạt hiệu suất tốt nhất với số lượng tham số tối thiểu. Những cải tiến này đã giúp CNN đạt được thành công vượt trội trong các nhiệm vụ như phân loại ảnh, phát hiện đối tượng, và đặc biệt là phân đoạn ảnh y tế.

Một xu hướng gần đây là áp dụng kiến trúc Transformer [2] vào thị giác máy tính thông qua Vision Transformer (ViT) [10]. ViT chia ảnh đầu vào thành các patch nhỏ có kích thước cố định, ánh xạ chúng thành chuỗi vector giống như token trong NLP, rồi đưa qua các lớp encoder Transformer. ViT cho phép mô hình học được các quan hệ toàn cục trong ảnh - điều mà các CNN truyền thống gặp hạn chế do bản chất cục bộ của phép tích chập. Dù ban đầu ViT đòi hỏi lượng dữ liệu lớn để huấn luyện hiệu quả, nhưng các biến thể sau này như DeiT (Data-efficient Image Transformer) [11] đã chứng minh rằng ViT có thể hoạt động tốt ngay cả trên tập dữ liệu vừa

phải nếu có kỹ thuật huấn luyện phù hợp. Cụ thể, DeiT đề xuất một cơ chế huấn luyện hiệu quả hơn bằng cách tích hợp distillation token - một kỹ thuật tri thức hóa mô hình (knowledge distillation) trong đó mô hình Transformer đóng vai trò học sinh, còn một mô hình CNN đã được huấn luyện trước (chẳng hạn như ResNet) giữ vai trò giáo viên. Thay vì chỉ học từ nhãn cứng (hard labels), mô hình học sinh còn học từ các phân phối xác suất mềm (soft targets) mà mô hình giáo viên cung cấp. Thông qua token đặc biệt này, mô hình Transformer có thể đồng thời học từ dữ liệu thật và kiến thức ẩn trong mô hình giáo viên, từ đó cải thiện khả năng khái quát và hiệu suất huấn luyện, đặc biệt trong bối cảnh dữ liệu không quá lớn. Nhờ chiến lược này, DeiT có thể huấn luyện từ đầu (from scratch) mà không cần pretraining trên các tập dữ liệu khổng lồ như JFT-300M [12], nhưng vẫn đạt hiệu suất cạnh tranh trên ImageNet [13]. Thành công của DeiT cho thấy rằng Transformer không chỉ phù hợp với dữ liệu quy mô lớn mà hoàn toàn có thể trở thành lựa chọn thực tế trong các bối cảnh dữ liệu hạn chế như ảnh y tế.

Học sâu hiện đại không chỉ dừng lại ở việc xử lý đơn lẻ một loại dữ liệu, mà còn tiến tới mô hình hóa các quan hệ đa mô thức - đặc biệt là giữa hình ảnh và văn bản. Một trong những mô hình tiên phong trong hướng tiếp cận này là CLIP (Contrastive Language-Image Pretraining) [14] do OpenAI giới thiệu. CLIP được huấn luyện để học biểu diễn cho cả ảnh và văn bản trong cùng một không gian nhúng (embedding space), sao cho những ảnh và mô tả ngôn ngữ phù hợp sẽ nằm gần nhau trong không gian này, còn những cặp không liên quan sẽ cách xa nhau. Cốt lõi của CLIP là kỹ thuật huấn luyện tương phản (contrastive learning), trong đó mô hình học cách phân biệt giữa các cặp ảnh-văn bản đúng và sai trong một minibatch lớn. Mô hình bao gồm hai thành phần chính: một encoder ảnh (thường là ResNet hoặc ViT) và một encoder văn bản (dựa trên Transformer). Cả hai encoder này ánh xạ đầu vào về các vector biểu diễn cùng chiều, sau đó mô hình sử dụng một hàm tương đồng như cosine similarity để đánh giá mức độ khớp giữa ảnh và văn bản. Mục tiêu huấn

luyện là tối đa hóa tương đồng giữa các cặp đúng (ví dụ ảnh chụp một con chó và dòng mô tả "a photo of a dog"), đồng thời tối thiểu hóa tương đồng giữa các cặp sai (ảnh con chó và mô tả "a photo of a banana").

Không giống các mô hình phân loại truyền thống cần nhãn cụ thể cho từng ảnh, CLIP có thể học từ dữ liệu web quy mô lớn chỉ với mô tả ngôn ngữ đi kèm ảnh. Sau khi huấn luyện, CLIP có khả năng tổng quát tốt cho các nhiệm vụ mà nó chưa từng được huấn luyện trực tiếp. Ví dụ, thay vì huấn luyện một mô hình phân loại với tập nhãn cố định, ta có thể cung cấp một tập mô tả văn bản (như “ảnh chụp khối u”, “ảnh bình thường”) và để CLIP chọn ảnh phù hợp nhất với từng mô tả, hoặc ngược lại. Sức mạnh của CLIP thể hiện rõ trong các ứng dụng y học, nơi mà ảnh y tế (chẳng hạn ảnh X-quang, MRI, siêu âm) thường đi kèm với báo cáo lâm sàng dưới dạng văn bản. Nhờ khả năng biểu diễn đa mô thức, CLIP có thể hỗ trợ truy vấn ảnh bằng văn bản mô tả triệu chứng, đối chiếu ảnh với nội dung báo cáo, hoặc hỗ trợ phân loại ảnh khi không có nhãn cụ thể mà chỉ có các chỉ dẫn ngôn ngữ mơ hồ. Trong những tình huống như vậy - khi dữ liệu có cấu trúc hỗn hợp giữa ảnh và văn bản, hoặc nhãn không rõ ràng - mô hình như CLIP mở ra khả năng triển khai linh hoạt, mạnh mẽ hơn các mô hình đơn mô thức truyền thống.

Nhìn chung, sự tiến hóa của các mô hình học sâu trong thị giác máy tính - từ các kiến trúc CNN như ResNet và EfficientNet [9] đến các mô hình Transformer như ViT [10] và DeiT [11] - đã mở rộng đáng kể khả năng biểu diễn và xử lý thông tin hình ảnh. Trong khi CNN khai thác hiệu quả các đặc trưng cục bộ với chi phí tính toán thấp, Transformer lại vượt trội trong việc học quan hệ toàn cục nhờ cơ chế tự chú ý. Đồng thời, các mô hình đa mô thức như CLIP [14], với chiến lược huấn luyện tương phản giữa ảnh và văn bản, đã chứng minh tiềm năng mạnh mẽ trong việc học các biểu diễn ngữ nghĩa chung và tổng quát hóa cho nhiều tác vụ chưa từng gặp. Những tiến bộ này không chỉ cải thiện độ chính xác trên các benchmark lớn mà còn đặt nền móng cho sự phát triển của các hệ thống thị giác máy tính linh hoạt, hiệu quả và có khả năng thích ứng cao với

những tình huống và yêu cầu mới trong thực tiễn ứng dụng.

2.1.3 Học sâu trong y khoa

Sự phát triển nhanh chóng của học sâu đã tạo ra bước ngoặt trong lĩnh vực y học, nơi dữ liệu hình ảnh - như MRI, CT, và siêu âm - giữ vai trò trung tâm trong quá trình chẩn đoán và điều trị. Các mạng nơ-ron tích chập (CNN) không chỉ giúp tự động hóa quá trình phát hiện bất thường trong ảnh y tế, mà còn cho phép trích xuất các đặc trưng hình thái học phức tạp vốn rất khó nhận diện bằng phương pháp thủ công. Đặc biệt trong các nhiệm vụ như phân đoạn mô tạng, xác định ranh giới tổn thương, hoặc tái tạo hình ảnh độ phân giải cao, mạng học sâu đã cho thấy độ chính xác và độ ổn định vượt trội so với các phương pháp truyền thống.

Không giống như các mô hình thị giác máy tính tổng quát như VGGNet [15] hay ResNet [8], nhiều kiến trúc đã được thiết kế chuyên biệt cho dữ liệu y tế. Trong số đó, U-Net [16], V-Net [17], và nnU-Net [18] là những kiến trúc nền tảng được phát triển nhằm thích nghi với tính chất đặc thù của ảnh y tế, như độ phân giải cao, số lượng mẫu hạn chế, và độ nhiễu lớn. Ngoài ra, các biến thể kết hợp như TransUNet [19] hay Swin-Unet [20], Swin UNETR [21] đã cho thấy hiệu quả nổi bật khi tích hợp các thành phần attention và kiến trúc Transformer để tăng cường khả năng biểu diễn và nhận diện mô hình.

Ở các tác vụ phát hiện tổn thương hoặc dị thường trong ảnh, nhiều nghiên cứu đã mở rộng hoặc tinh chỉnh các framework detection để áp dụng vào y tế. DeepLesion [22] sử dụng kiến trúc CNN đa nhiệm để phát hiện và định lượng tổn thương trên ảnh CT toàn thân. Một hướng tiếp cận đáng chú ý khác là nnDetection [23], một hệ thống tự cấu hình cho bài toán phát hiện đối tượng y tế, cho phép mô hình tự động thích ứng với cấu trúc và phân phối của từng tập dữ liệu. Gần đây, các hệ thống dựa trên self-supervised hoặc anomaly detection, cũng được áp dụng để phát hiện dị thường mà không cần nhãn đầy đủ, mở ra hướng đi mới cho các

bài toán thiếu dữ liệu gán nhãn.

Bên cạnh ảnh tĩnh, dữ liệu chuỗi sinh lý như điện tâm đồ (ECG), điện não đồ (EEG) hay dữ liệu theo dõi lâm sàng theo thời gian thực cũng nhận được sự quan tâm mạnh mẽ. Các mô hình học sâu như LSTM [24], GRU [25], hoặc hybrid CNN-RNN [26] được sử dụng để mô hình hóa quan hệ thời gian và dự đoán các tình trạng sức khỏe tiềm ẩn. DeepHeart [27] là một ví dụ nổi bật, ứng dụng LSTM để phát hiện rối loạn nhịp tim từ thiết bị wearable. Trong khi đó, các mô hình như DeepSleepNet [28] cho thấy hiệu quả trong phân loại giai đoạn giấc ngủ từ tín hiệu EEG thô, hỗ trợ chẩn đoán các rối loạn liên quan đến giấc ngủ.

Tuy vậy, có một số thách thức vẫn còn tồn tại trong việc ứng dụng học sâu vào y khoa:

- Thiếu dữ liệu gán nhãn chất lượng cao: Việc thu thập và gán nhãn dữ liệu y khoa đòi hỏi chuyên môn sâu và quy trình kiểm định chặt chẽ, dẫn đến nguồn dữ liệu hạn chế và không đồng nhất.
- Tính minh bạch và khả năng giải thích: Mô hình học sâu, đặc biệt là các mô hình lớn, thường được xem như “hộp đen”, gây khó khăn trong việc kiểm chứng lâm sàng và tạo niềm tin cho bác sĩ.
- Khả năng tổng quát kém giữa các cơ sở y tế: Mô hình huấn luyện trên một bộ dữ liệu tại một bệnh viện có thể hoạt động không hiệu quả khi áp dụng cho dữ liệu từ cơ sở khác do sự khác biệt về thiết bị, giao thức, dân số bệnh nhân.

Chính vì thế, các hướng nghiên cứu gần đây tập trung vào các giải pháp như học chuyển tiếp (transfer learning) [29], học liên kết (federated learning) [30], học bán giám sát (semi-supervised learning) [31], và các mô hình khả năng giải thích (explainable AI - XAI) [32] nhằm giải quyết những hạn chế nêu trên.

Nhìn chung thì học sâu đã và đang thúc đẩy quá trình tự động hóa và tối ưu hóa các tác vụ phân tích dữ liệu y tế. Việc kết hợp các mô hình

chuyên biệt, kỹ thuật học tiên tiến và các biện pháp đảm bảo tính khả giải thích sẽ đóng vai trò then chốt trong việc đưa AI vào thực hành lâm sàng một cách an toàn và hiệu quả.

2.1.4 Phân đoạn ảnh y khoa

Phân đoạn ảnh là một bước quan trọng trong chuỗi xử lý ảnh y tế, đóng vai trò thiết yếu trong việc xác định biên, vị trí và kích thước của các cấu trúc giải phẫu hoặc vùng tổn thương. Việc phân đoạn chính xác giúp hỗ trợ bác sĩ trong quá trình chẩn đoán, theo dõi tiến triển bệnh, lên kế hoạch điều trị, và đánh giá kết quả can thiệp. Trong nhiều trường hợp, phân đoạn tự động còn đóng vai trò như bước tiền xử lý trong các hệ thống phân tích ảnh y tế quy mô lớn.

Trong đó, ảnh siêu âm là một trong những loại ảnh y khoa được sử dụng phổ biến nhất nhờ ưu điểm về chi phí thấp, tính di động cao, an toàn không xâm lấn và thời gian thu ảnh nhanh. Tuy nhiên, phân đoạn ảnh siêu âm lại đặt ra nhiều thách thức kỹ thuật hơn so với các loại ảnh khác như MRI hay CT, bởi chất lượng hình ảnh thường bị ảnh hưởng bởi nhiễu speckle, độ phân giải thấp, và sự biến thiên lớn giữa các thiết bị siêu âm cũng như đặc điểm giải phẫu của bệnh nhân. Những yếu tố này khiến cho việc phân đoạn thủ công đòi hỏi kỹ năng chuyên môn cao và thời gian xử lý lâu, trong khi phân đoạn tự động thì khó đạt được độ chính xác ổn định.

Một trong những kiến trúc thành công nhất trong xử lý phân đoạn ảnh y khoa là U-Net [16], được giới thiệu lần đầu bởi Ronneberger vào năm 2015. Mô hình này được thiết kế đặc biệt cho các bài toán phân đoạn ảnh y tế với quy mô dữ liệu hạn chế. U-Net có cấu trúc đối xứng hình chữ “U”, gồm hai phần chính: nhánh downsampling (bên trái) giúp trích xuất đặc trưng không gian từ ảnh đầu vào thông qua các tầng chập và pooling, và nhánh upsampling (bên phải) khôi phục lại kích thước ảnh ban đầu để tạo ra mặt nạ phân đoạn (segmentation mask). Một điểm quan trọng làm nên

thành công của U-Net là cơ chế skip connection - cho phép truyền trực tiếp các đặc trưng cục bộ từ nhánh xuống sang nhánh lên, giúp giữ lại thông tin chi tiết cần thiết cho việc xác định ranh giới chính xác của các vùng cần phân đoạn.

Kể từ đó, nhiều biến thể của U-Net đã được đề xuất nhằm nâng cao hiệu suất phân đoạn trong những tình huống phức tạp hơn. Điển hình như U-Net++ [33] đã giúp cải tiến kiến trúc gốc bằng cách bổ sung các kết nối chéo dày đặc (nested skip connections) giữa các tầng có cùng độ phân giải. Điều này giúp tăng khả năng học biểu diễn đa cấp và giảm khoảng cách ngữ nghĩa giữa các đặc trưng trong encoder và decoder. Hay Attention U-Net [34] tích hợp cơ chế attention để mô hình học cách tập trung vào các vùng quan trọng trong ảnh, từ đó bỏ qua các vùng nhiễu hoặc không liên quan. Đây là một điểm mạnh trong bối cảnh ảnh siêu âm thường chứa nhiều vùng mờ và nhiễu. Thêm một kiến trúc nữa là ResUNet [35] đã kết hợp U-Net với các khối residual từ ResNet [8] để cải thiện khả năng truyền gradient và giúp mô hình ổn định hơn khi huấn luyện với dữ liệu nhiễu hoặc phức tạp.

Bên cạnh các biến thể cổ điển kể trên, các kiến trúc U-Net hiện đại hơn đã được phát triển để tận dụng sức mạnh của kiến trúc Transformer [2] trong việc học các quan hệ không gian-ngữ nghĩa toàn cục. Một trong những hướng tiêu biểu là UNetR [36], một mô hình tích hợp Vision Transformer (ViT) [10] làm bộ mã hóa chính trong kiến trúc U-Net. Khác với U-Net truyền thống dựa trên CNN, UNetR sử dụng ViT để trích xuất đặc trưng từ toàn bộ ảnh đầu vào dưới dạng patch, từ đó nắm bắt được thông tin dài hạn và cấu trúc toàn cục tốt hơn - điều đặc biệt quan trọng trong các bài toán phân đoạn vùng tổn thương không đồng nhất hoặc có biên mờ như trong ảnh siêu âm.

UNetR giữ nguyên tinh thần “U” đối xứng của U-Net, nhưng thay vì dùng các tầng convolution cho phần encoder, nó sử dụng một chuỗi các lớp Transformer encoder để học biểu diễn không gian. Kết quả từ các tầng khác nhau trong ViT sẽ được đưa vào nhánh decoder thông qua các kết nối

skip, giúp duy trì cấu trúc đa cấp và thông tin chi tiết trong quá trình tái dựng mặt nạ phân đoạn. Nhờ kết hợp giữa khả năng học ngữ nghĩa toàn cục của Transformer và cấu trúc phân cấp đặc trưng của U-Net, UNetR cho thấy hiệu quả vượt trội trong nhiều tác vụ phân đoạn y khoa.

Tiếp nối UNetR, kiến trúc Swin-UNetR [21] khai thác Swin Transformer [37] - một biến thể hiệu quả hơn của ViT - làm backbone cho encoder. Swin Transformer chia ảnh thành các patch nhỏ và áp dụng self-attention cục bộ trong các cửa sổ trượt (shifted windows), giúp giảm chi phí tính toán đồng thời vẫn bảo toàn được khả năng học đặc trưng toàn cục. Trong Swin-UNetR, mô hình không chỉ tận dụng kiến trúc phân cấp của Swin để học đặc trưng ở nhiều mức độ chi tiết khác nhau, mà còn thiết kế nhánh decoder phù hợp để kết hợp linh hoạt các đặc trưng từ các tầng khác nhau. Swin-UNetR đã chứng minh hiệu quả rõ rệt trong các tác vụ phân đoạn đa mô thức như CT, MRI và ảnh siêu âm với cấu trúc phức tạp.

Gần đây, mô hình UNetR++ [38] được đề xuất như một cải tiến trực tiếp của UNetR nhằm giải quyết một số hạn chế còn tồn tại, chẳng hạn như khoảng cách ngữ nghĩa giữa các tầng mã hóa và giải mã, cũng như sự thiếu hiệu quả trong tích hợp đặc trưng giữa các mức. UNetR++ giới thiệu các khối giải mã đa tầng (multi-scale decoder blocks) và thiết kế lại chiến lược skip connection để tăng cường luồng thông tin giữa encoder-decoder. Bên cạnh đó, mô hình còn sử dụng các chiến lược huấn luyện hiệu quả hơn như deep supervision để đảm bảo việc hội tụ tốt hơn trong các bài toán có độ phức tạp cao. Nhờ các cải tiến này, UNetR++ cho kết quả phân đoạn mịn hơn và chính xác hơn, đặc biệt là trong các vùng tổn thương nhỏ, ranh giới mờ - rất phổ biến trong ảnh siêu âm.

Ngoài ra không thể không kể đến nnU-Net [18], mô hình được xem như một khuôn mẫu tự động cho các bài toán segmentation. Thay vì đề xuất một kiến trúc mới, nnU-Net xây dựng một framework có khả năng tự điều chỉnh toàn bộ pipeline - từ tiền xử lý dữ liệu, lựa chọn kiến trúc mạng, đến huấn luyện và hậu xử lý - dựa trên đặc điểm của tập dữ liệu đầu vào. Mô hình này không chỉ giúp đơn giản hóa quy trình triển khai hệ thống

phân đoạn, mà còn đạt kết quả hàng đầu trên nhiều benchmark y học như BraTS (não), KiTS (thận), và LiTS (gan). Nhờ khả năng thích nghi cao và hiệu quả vượt trội, nnU-Net đã nhanh chóng trở thành một baseline tiêu chuẩn trong nghiên cứu và ứng dụng phân đoạn ảnh y khoa hiện đại.

Các mô hình như UNetR [36], Swin-UNetR [21], và UNetR++ [38] hay nnU-Net [18] cho thấy xu hướng hiện đại hóa kiến trúc phân đoạn ảnh y khoa bằng cách kết hợp thế mạnh của CNN truyền thống (trích xuất đặc trưng cục bộ, hiệu quả tính toán) với Transformer (hiểu ngữ cảnh toàn cục, biểu diễn sâu hơn). Khi áp dụng vào ảnh siêu âm - nơi mà ranh giới mô thường không rõ ràng, tín hiệu bị nhiễu và cấu trúc giải phẫu thay đổi đáng kể, các kiến trúc này giúp cải thiện đáng kể hiệu suất phân đoạn, mở ra khả năng ứng dụng thực tiễn trong hỗ trợ chẩn đoán lâm sàng và các hệ thống y tế thông minh.

2.2 Human-in-the-loop và Học sâu chủ động

2.2.1 Human-in-the-Loop

Xây dựng các hệ thống phân đoạn ảnh y tế chất lượng cao luôn gặp phải rào cản lớn về dữ liệu gán nhãn. Đặc biệt với ảnh siêu âm - một trong những phương thức chẩn đoán phổ biến tại các cơ sở y tế tuyến dưới - việc gán nhãn thủ công không chỉ đòi hỏi kiến thức chuyên môn sâu mà còn tốn nhiều thời gian và công sức, do ảnh thường có nhiễu cao, biên mờ, và phụ thuộc vào kỹ năng người vận hành. Trong bối cảnh đó, Human-in-the-Loop (HITL) [39] nổi lên như một chiến lược đầy hứa hẹn, kết hợp giữa khả năng học của mô hình và sự điều hướng linh hoạt từ chuyên gia lâm sàng.

Khác với các phương pháp học hoàn toàn tự động, HITL duy trì vòng lặp tương tác giữa mô hình và con người, cho phép mô hình học được các đặc trưng khó nắm bắt mà chỉ có chuyên gia mới có thể đánh giá chính xác. Giao diện trực quan và các công cụ can thiệp đơn giản như chỉnh sửa

vùng phân đoạn, thêm điểm nhấn hoặc sửa biên giúp giảm đáng kể công sức gán nhãn toàn phần, trong khi vẫn đảm bảo độ tin cậy lâm sàng.

Một số hệ thống gần đây như MedUHIP [40] cho phép chuyên gia tương tác nhanh với kết quả phân đoạn ban đầu của mô hình, từ đó tạo ra các chỉnh sửa có thể được sử dụng để cập nhật mô hình theo thời gian thực. Tương tự, PRISM Lite [41] áp dụng trong ảnh siêu âm thai kỳ đã chứng minh hiệu quả của vòng lặp tương tác liên tục trong cải thiện chất lượng phân đoạn 3D với số lần can thiệp tối thiểu.

Tuy nhiên, HITL vẫn còn đối mặt với nhiều thách thức thực tiễn. Phần lớn các nghiên cứu hiện nay tập trung vào dữ liệu chất lượng cao như MRI hoặc CT, trong khi những loại ảnh phổ biến hơn nhưng nhiều khó khăn hơn, chẳng hạn như siêu âm, vẫn chưa nhận được sự quan tâm tương xứng. Ngoài ra, nhiều hệ thống còn thiếu các cơ chế cập nhật mô hình một cách hiệu quả từ dữ liệu phản hồi, đặc biệt là khi phải duy trì tính ổn định của mô hình mà không được huấn luyện lại toàn bộ mạng lưới. Một số nghiên cứu đã bắt đầu áp dụng incremental learning với tốc độ học thấp (low learning rate) nhằm cập nhật mô hình dựa trên các tương tác trực tiếp của chuyên gia mà vẫn hạn chế hiện tượng catastrophic forgetting [42]. Cách tiếp cận này mở ra triển vọng xây dựng các hệ thống phân đoạn ảnh y tế thông minh, có khả năng thích ứng nhanh với dữ liệu và điều kiện thực tế lâm sàng, đồng thời tận dụng tối đa giá trị của các phản hồi từ chuyên gia.

2.2.2 Học sâu chủ động

Học sâu chủ động (Deep Active Learning - DAL) [43] là một hướng tiếp cận kết hợp giữa học sâu và học chủ động, nhằm tối ưu hóa hiệu quả huấn luyện trong bối cảnh dữ liệu gán nhãn hạn chế - một đặc điểm phổ biến trong y khoa. Không giống như các mô hình học sâu truyền thống vốn cần lượng lớn dữ liệu đã gán nhãn, DAL cho phép mô hình chủ động lựa chọn những mẫu dữ liệu chưa gán nhãn mà nó "muốn học" nhất - tức những mẫu mang lại nhiều thông tin nhất - để từ đó tiết kiệm chi phí gán nhãn

mà vẫn đảm bảo chất lượng mô hình. Quy trình của DAL thường bao gồm các bước chính: (1) huấn luyện mô hình ban đầu trên một tập dữ liệu gán nhãn nhỏ (initial labeled set); (2) chọn mẫu chưa gán nhãn từ tập dữ liệu lớn dựa trên một chiến lược lựa chọn mẫu (acquisition function); (3) gán nhãn các mẫu được chọn bởi chuyên gia (bác sĩ hoặc annotator); (4) cập nhật mô hình với tập dữ liệu mới vừa được gán nhãn; và (5) lặp lại các bước (2)-(4) cho đến khi đạt hiệu năng mong muốn hoặc vượt ngưỡng chi phí cho phép.

Nhiều phương pháp DAL hiện nay dựa trên việc đo lường độ bất định của mô hình trong quá trình dự đoán. Các chiến lược chọn mẫu phổ biến bao gồm Confidence Sampling - chọn các mẫu có xác suất dự đoán cao nhất cho nhãn không đúng (tức là mô hình “quá tự tin” nhưng sai); Margin Sampling - ưu tiên các mẫu mà sự chênh lệch giữa hai xác suất nhãn cao nhất là nhỏ nhất, cho thấy sự mơ hồ trong phân loại [44]; và Entropy Sampling - lựa chọn các mẫu có phân bố xác suất đầu ra có độ hỗn loạn cao nhất [45]. Một chiến lược khác là BALD (Bayesian Active Learning by Disagreement) [46] [47], trong đó độ bất định được định lượng dựa trên sự không đồng thuận giữa các mô hình trong ensemble.

Bên cạnh các phương pháp dựa trên bất định, các chiến lược chọn mẫu dựa trên tính đại diện cũng đóng vai trò quan trọng. Core-set [48] và Cluster-Margin [49] nhằm mục tiêu chọn ra tập con các mẫu có khả năng đại diện cho toàn bộ phân bố dữ liệu chưa gán nhãn. BADGE [50] là một phương pháp kết hợp bất định và tính đại diện, trong đó các mẫu được chọn thông qua thuật toán clustering dựa trên vector gradient (đại diện cho hướng cập nhật mô hình nếu mẫu đó được gán nhãn). Các phương pháp học sâu chủ động gần đây cũng đưa ra nhiều chiến lược học dựa trên mô hình phụ như Learning Loss, VAAL (Variational Adversarial Active Learning) [51], nơi mạng con học cách dự đoán độ khó hoặc mức độ thông tin của từng mẫu chưa gán nhãn.

Trong lĩnh vực ảnh y tế, DAL đã được áp dụng hiệu quả trên nhiều mô hình học sâu như U-Net [16], UNet++ [33], hoặc Swin-UNet [21], cùng

với nhiều dạng dữ liệu hình ảnh khác nhau như ảnh hiển vi mô bệnh học (WSI) [52], ảnh siêu âm [53], và X-quang [54]. Ngoài ra, HAL-IA [55] đã giới thiệu một pipeline gán nhãn tương tác chuyên biệt cho dữ liệu y tế tổng quát, giúp chuyên gia dễ dàng đánh dấu và cập nhật nhãn qua các vòng lặp học nhanh. Những hướng tiếp cận này cho thấy tiềm năng của DAL trong môi trường dữ liệu hạn chế và đa dạng như ảnh y khoa.

Tuy nhiên, phần lớn các phương pháp DAL hiện tại vẫn dựa trên mô hình chính để lựa chọn mẫu, điều này dẫn đến hiệu suất không ổn định ở giai đoạn đầu khi tập gán nhãn ban đầu còn nhỏ và mô hình chưa tổng quát tốt. Điều này đặt ra thách thức cho việc thiết kế các chiến lược chọn mẫu hiệu quả ngay từ giai đoạn khởi đầu. Một giải pháp tiềm năng là tích hợp DAL với Human-in-the-Loop (HITL) [40], nhằm kết hợp sức mạnh của máy học và phản hồi của chuyên gia. Trong mô hình này, DAL không chỉ tự động chọn mẫu khó mà còn hỗ trợ bác sĩ gán nhãn qua các thao tác trực quan, đồng thời cập nhật mô hình liên tục. Điều này đặc biệt hữu ích trong môi trường lâm sàng, nơi yêu cầu cao về độ chính xác và khả năng phản hồi theo thời gian thực.

Nhìn chung, học sâu chủ động (DAL) đang mở ra một hướng đi bền vững cho việc phát triển các hệ thống AI trong các lĩnh vực nhạy cảm về dữ liệu. Khi kết hợp với kiến trúc mô hình mạnh, kỹ thuật chọn mẫu tiên tiến và tương tác hiệu quả từ chuyên gia, DAL có thể trở thành nền tảng cốt lõi cho các hệ thống học máy thông minh, thích ứng nhanh và chi phí thấp.

2.3 Mô hình cơ sở

2.3.1 Mô hình ảnh tự nhiên

Trong các hệ thống học sâu hiện đại, việc khởi tạo mô hình với trọng số được huấn luyện sẵn (pretrained weights) đã trở thành một chiến lược phổ biến nhằm tăng tốc quá trình huấn luyện và cải thiện hiệu quả tổng

quát hóa. Điều này đặc biệt quan trọng trong các tác vụ thị giác máy tính, nơi dữ liệu gán nhãn thường tốn kém và khó thu thập.

Một trong những mô hình tiền huấn luyện nổi bật gần đây là DINOv2 [56], được phát triển dựa trên DINO [57] và sử dụng kiến trúc Vision Transformer (ViT) [10]. DINOv2 áp dụng cơ chế self-distillation without labels, trong đó hai mô hình Transformer - giáo viên và học sinh - cùng học các biểu diễn đặc trưng từ dữ liệu không gán nhãn thông qua các biến thể hình ảnh và kỹ thuật học tương phản (contrastive learning). Phương pháp này cho phép mô hình thu nhận các biểu diễn toàn cục mang tính khái quát và ngữ nghĩa cao. Nhờ đó, DINOv2 đã chứng minh hiệu quả khi được sử dụng như backbone cho các tác vụ như phân đoạn hoặc phân loại mà không cần huấn luyện lại toàn bộ mạng.

Một hướng tiếp cận đáng chú ý khác là Segment Anything Model (SAM) [58], một mô hình phân đoạn tổng quát được phát triển bởi Meta AI. SAM được xây dựng trên nền tảng Vision Transformer và được huấn luyện trên một tập dữ liệu cực lớn gồm hơn một tỷ mặt nạ phân đoạn thu thập từ nhiều miền dữ liệu khác nhau - bao gồm ảnh tự nhiên, ảnh tổng hợp và ảnh kỹ thuật số. Điểm nổi bật của SAM nằm ở khả năng phân đoạn theo yêu cầu (promptable segmentation), cho phép người dùng tạo mặt nạ chỉ với những tín hiệu đầu vào đơn giản như điểm ảnh, khung giới hạn hoặc phác thảo hình dạng.

Khác với các mô hình phân đoạn truyền thống vốn cần được huấn luyện riêng biệt cho từng tác vụ, SAM được thiết kế để hoạt động như một hệ thống phân đoạn phổ quát mà không yêu cầu tinh chỉnh thêm. Kiến trúc của SAM bao gồm ba thành phần chính: (1) bộ mã hóa ảnh (image encoder) - thường là một ViT lớn, dùng để trích xuất đặc trưng từ ảnh đầu vào; (2) bộ mã hóa prompt (prompt encoder) - chuyển các tín hiệu đầu vào từ người dùng sang không gian biểu diễn; và (3) bộ giải mã mặt nạ (mask decoder) - kết hợp đặc trưng ảnh và prompt để tạo ra mặt nạ phân đoạn phù hợp. SAM còn được tối ưu để chạy hiệu quả, hỗ trợ tốt cho các ứng dụng tương tác thời gian thực.

Bên cạnh đó, nhiều phương pháp học tự giám sát cũng đã cho thấy hiệu quả trong việc học biểu diễn từ dữ liệu không gán nhãn. Một trong những đại diện tiêu biểu là MAE (Masked Autoencoders) [59], lấy cảm hứng từ kiến trúc BERT [3] trong xử lý ngôn ngữ tự nhiên. MAE học biểu diễn bằng cách che giấu một phần lớn ảnh đầu vào (thường lên đến 75%) và yêu cầu mô hình tái dựng lại ảnh gốc từ phần còn lại. Chiến lược này buộc bộ mã hóa (encoder) học các đặc trưng tổng quát và ngữ nghĩa mạnh, trong khi cũng giúp giảm chi phí tính toán bằng cách chỉ xử lý các patch không bị che. MAE đã đạt được kết quả tốt trên nhiều nhiệm vụ thị giác như phân loại ảnh, phát hiện đối tượng và phân đoạn hình ảnh.

Bên cạnh các phương pháp tái dựng ảnh, các mô hình học biểu diễn dựa trên học tương phản (contrastive learning) như SimCLR [60] và MoCo [61] đã đạt được nhiều kết quả nổi bật. Những mô hình này học cách phân biệt các cặp ảnh dương - âm bằng cách tối đa hóa khoảng cách giữa các mẫu không liên quan và thu hẹp khoảng cách giữa các biến thể khác nhau của cùng một ảnh. Đặc biệt, MoCo giới thiệu cơ chế bộ mã hóa động (momentum encoder), cho phép duy trì một bộ nhớ mẫu âm lớn và ổn định trong suốt quá trình huấn luyện. Ở một hướng tiếp cận kết hợp, BEiT [62] tích hợp cơ chế che patch từ MAE và phương pháp học token theo phong cách BERT, trong đó mô hình được yêu cầu dự đoán mã định danh của các patch ảnh trong không gian mã hóa. Cách tiếp cận này giúp mô hình học được các biểu diễn giàu tính ngữ nghĩa từ dữ liệu không gán nhãn.

Song song với sự phát triển của các mô hình Transformer [2], các backbone CNN truyền thống như ResNet [8], EfficientNet [9] và DenseNet [63] vẫn giữ vai trò cốt lõi trong nhiều hệ thống thị giác máy tính hiện nay. Những kiến trúc này không chỉ chứng minh hiệu quả trong việc trích xuất đặc trưng mà còn dễ dàng tích hợp vào các mô hình phân đoạn mạnh mẽ như UNet [16] và DeepLab [64]. Ngoài ra, việc sử dụng các backbone đã được tiền huấn luyện trên tập dữ liệu lớn giúp tăng tốc quá trình huấn luyện và cải thiện khả năng khái quát trên các miền dữ liệu khác nhau, từ đó nâng cao hiệu suất của các hệ thống thị giác quy mô lớn.

2.3.2 Mô hình ảnh y khoa

Trong bối cảnh dữ liệu gán nhãn trong lĩnh vực hình ảnh y tế thường khan hiếm và tốn kém để thu thập, việc sử dụng các mô hình backbone với trọng số tiền huấn luyện từ các tập dữ liệu thị giác quy mô lớn như ImageNet [13] hay LAION-5B [65] đã trở thành một hướng đi hiệu quả. Các trọng số này giúp mô hình nắm bắt được các đặc trưng hình ảnh cơ bản, từ đó dễ dàng thích nghi với các tác vụ chuyên biệt như phân đoạn mô tạng, nhận diện tổn thương, hoặc phân loại ảnh chẩn đoán.

Tuy nhiên, các mô hình thị giác tổng quát không phải lúc nào cũng phù hợp khi áp dụng trực tiếp cho dữ liệu y tế. Điển hình là Segment Anything Model (SAM) [58] - một mô hình phân đoạn mạnh mẽ được huấn luyện trên tập dữ liệu đa miền với hơn một tỷ mặt nạ - khi được sử dụng cho ảnh y khoa thường gặp phải một số thách thức. Ảnh y tế đặc trưng bởi nhiễu cao, biên mờ, độ tương phản thấp và các cấu trúc giải phẫu phức tạp có kích thước nhỏ, khiến SAM - vốn không được huấn luyện trên dữ liệu y học - khó xác định chính xác các vùng tổn thương hoặc ranh giới mô tạng. Ngoài ra, sự khác biệt miền (domain gap) giữa ảnh tự nhiên và ảnh y khoa cũng làm giảm khả năng tổng quát hóa của mô hình trong môi trường lâm sàng.

Nhằm khắc phục những hạn chế này, nhiều biến thể của SAM đã được phát triển để thích nghi tốt hơn với dữ liệu y tế. MedSAM [66] là một phiên bản được huấn luyện lại từ SAM trên các tập dữ liệu y khoa có gán nhãn như CT, MRI hoặc siêu âm. Việc fine-tune trên dữ liệu chuyên biệt giúp mô hình học được các đặc trưng cấu trúc giải phẫu, cải thiện độ chính xác khi xử lý các mô tạng có hình dạng biến đổi và biên mờ. Trong khi đó, SAMed [67] áp dụng chiến lược thích nghi miền mà không cần huấn luyện lại toàn bộ mô hình. SAMed giữ nguyên backbone gốc của SAM nhưng sử dụng các kỹ thuật như prompt tuning, adapter modules hoặc layer-wise adaptation để tinh chỉnh linh hoạt các tầng, nhằm tối ưu hóa hiệu suất trên ảnh y tế. Gần đây hơn, SAMUS [68] được thiết kế đặc biệt cho ảnh

siêu âm, tập trung vào tiền xử lý để giảm nhiễu và tăng độ phân biệt biên, đồng thời điều chỉnh kiến trúc encoder hoặc prompt cho phù hợp với hình thái học siêu âm. Các nghiên cứu đã cho thấy rằng những biến thể như MedSAM, SAMed [67] và SAMUS đều cải thiện đáng kể độ chính xác phân đoạn so với SAM, đồng thời chứng minh tính khả thi khi triển khai trong hệ thống chẩn đoán hình ảnh y khoa. Những kết quả này cũng nhấn mạnh rằng, để đạt hiệu quả cao trong môi trường lâm sàng, việc điều chỉnh mô hình thị giác tổng quát theo miền ứng dụng là điều thiết yếu.

Bên cạnh các mô hình phân đoạn, một xu hướng quan trọng khác trong thị giác y khoa là sự kết hợp giữa hình ảnh và ngôn ngữ. Một ví dụ điển hình là BiomedCLIP [69], một phiên bản điều chỉnh của CLIP [14] được huấn luyện trên tập dữ liệu kết hợp giữa ảnh y tế (như X-quang, CT) và văn bản y học (báo cáo lâm sàng, tiêu đề học thuật). Thông qua học tương phản giữa ảnh và văn bản, BiomedCLIP khai thác mối liên kết ngữ nghĩa giữa nội dung hình ảnh và kiến thức y học, từ đó nâng cao khả năng hiểu ngữ cảnh chuyên ngành. BiomedCLIP đã chứng minh hiệu quả vượt trội trong các tác vụ như phân loại ảnh chẩn đoán, truy vấn ảnh theo mô tả bệnh lý hoặc sinh văn bản từ ảnh.

Với dữ liệu chuyên biệt hơn như ảnh mô bệnh học (histopathology), CONCH (Contrastive Captioner for Histopathology) [70] được đề xuất như một biến thể của CLIP phù hợp với ảnh có độ phân giải cao và cấu trúc vi mô phức tạp. CONCH [70] không chỉ huấn luyện tương phản giữa ảnh và mô tả mà còn tích hợp một module captioner, cho phép sinh văn bản tự động mô tả hình ảnh mô học. Kết hợp giữa huấn luyện tương phản và sinh ngôn ngữ có điều kiện giúp mô hình học tốt hơn các biểu diễn ngữ nghĩa phức tạp, từ đó nâng cao hiệu suất trong các tác vụ như phân loại mô bệnh học hoặc tìm kiếm ảnh theo văn bản trên tập TCGA [71] và Camelyon [72].

Tổng thể, những hướng tiếp cận nêu trên thể hiện tiềm năng to lớn của các mô hình thị giác tiền huấn luyện và mô hình ngôn ngữ-hình ảnh trong lĩnh vực y khoa. Việc khai thác sức mạnh của các backbone học sâu hiện

đại, cùng với các chiến lược tinh chỉnh hoặc thích nghi miền, không chỉ giúp vượt qua rào cản dữ liệu gán nhãn hạn chế mà còn mở ra khả năng triển khai các hệ thống hỗ trợ chẩn đoán chính xác, đáng tin cậy và linh hoạt trong môi trường lâm sàng.

2.4 Pipelines xử lý dữ liệu và đánh giá mô hình

Trong các bài toán phân đoạn ảnh y khoa, việc xây dựng một quy trình xử lý dữ liệu (pipeline) chặt chẽ và hợp lý đóng vai trò then chốt, ảnh hưởng trực tiếp đến hiệu quả huấn luyện và độ chính xác của mô hình. Một pipeline điển hình thường bao gồm các bước chính: (1) thu thập và gán nhãn dữ liệu; (2) tiền xử lý dữ liệu; (3) huấn luyện mô hình phân đoạn; (4) hậu xử lý kết quả và (5) đánh giá mô hình bằng các chỉ số định lượng phù hợp. Mỗi bước đều có các kỹ thuật và chiến lược riêng nhằm đối phó với những đặc điểm đặc thù của dữ liệu ảnh y khoa, đặc biệt là ảnh siêu âm vốn nổi bật với nhiễu cao, độ tương phản thấp, và ranh giới mô không rõ ràng.

2.4.1 Tiền xử lý dữ liệu

Nhiều công trình đã nhấn mạnh vai trò của các kỹ thuật tiền xử lý trong việc cải thiện chất lượng ảnh đầu vào. Ví dụ, các bộ lọc không gian như anisotropic diffusion và median filtering được sử dụng để loại bỏ speckle noise - một dạng nhiễu phổ biến trong ảnh siêu âm - trong khi vẫn bảo tồn biên mô học [73]. Ngoài ra, chuẩn hóa cường độ (z-score hoặc min-max normalization) là bước cần thiết để đưa ảnh về cùng không gian đặc trưng, đặc biệt khi sử dụng backbone đã được tiền huấn luyện. Tăng cường dữ liệu (data augmentation) cũng là chiến lược phổ biến để mở rộng tập huấn luyện và giảm overfitting trong bối cảnh dữ liệu y tế thường bị giới hạn. Các biến đổi như xoay, phóng to, lật, hoặc biến dạng đàn hồi

(elastic deformation) được chứng minh là hữu ích trong việc mô phỏng các biến thể giải phẫu học và tăng tính khái quát hóa của mô hình [16].

2.4.2 Hậu xử lý dữ liệu

Về mặt hậu xử lý, mục tiêu chính là cải thiện chất lượng và độ ổn định của kết quả phân đoạn sau khi mô hình dự đoán. Các phương pháp phổ biến bao gồm việc loại bỏ các đối tượng nhỏ hoặc nhiễu không mong muốn, làm mượt biên phân đoạn để giảm hiệu ứng răng cưa, và đảm bảo tính nhất quán hình học của các vùng được phân đoạn. Những kỹ thuật này thường dựa trên các phép toán hình thái học (morphological operations), làm mờ bằng Gaussian, hoặc sử dụng các thuật toán lọc theo kích thước và hình dạng. Ngoài ra, trong các pipeline hiện đại, phân đoạn thường được thực hiện trên nhiều phiên bản biến đổi của ảnh đầu vào (augmentation), sau đó kết quả được ánh xạ ngược trở lại không gian ban đầu và tổng hợp để tạo ra mặt nạ cuối cùng. Quá trình này không chỉ giúp tăng cường độ chính xác bằng cách kết hợp thông tin từ nhiều quan sát mà còn tạo điều kiện để xây dựng các bản đồ bất định (uncertainty maps), phản ánh độ tin cậy của mô hình đối với từng vùng trong ảnh. Hậu xử lý do đó đóng vai trò quan trọng trong việc nâng cao chất lượng đầu ra và đảm bảo khả năng ứng dụng thực tế của hệ thống.

2.4.3 Đánh giá mô hình

Đánh giá mô hình phân đoạn là bước không thể thiếu để kiểm chứng chất lượng và độ tin cậy. Dice Similarity Coefficient (DSC) và Jaccard Coefficient (JC) là hai trong số chỉ số phổ biến nhất, được sử dụng để đo độ chồng lặp giữa mặt nạ dự đoán và ground truth, phù hợp để đánh giá khả năng trùng khớp vùng phân đoạn [74]. DSC đặc biệt nhấn mạnh phần giao nhau, làm cho nó hữu ích trong các tình huống vùng mục tiêu nhỏ hoặc không đồng nhất. Song song đó, các chỉ số khoảng cách như HD (Hausdorff Distance) [75] và ASD (Average Surface Distance) được dùng

để kiểm tra độ chính xác của ranh giới phân đoạn—yếu tố quan trọng trong các ứng dụng cần độ biên mượt và chuẩn xác [74]. Trong đó, HD đo khoảng cách cực đại giữa biên dự đoán và thực tế (ground truth), trong khi ASD tính trung bình sai lệch giữa hai đường biên. Để giảm ảnh hưởng của các điểm ngoại lai (outliers), phiên bản HD95 được dùng phổ biến hơn, lấy giá trị phân vị thứ 95 thay vì giá trị cực đại.

Ngoài ra, một số nghiên cứu gần đây còn đề xuất kết hợp nhiều chỉ số để đánh giá toàn diện hơn [76]. Thêm vào đó phương pháp khuyến nghị rằng mỗi chỉ số chỉ phù hợp với một khía cạnh cụ thể và việc kết hợp Dice, HD95 và VS (volume similarity) có thể phản ánh đầy đủ hơn hiệu suất mô hình trên cả vùng lớn và biên phức tạp.

Chương 3


Phương pháp đề xuất

Hình 3.1 minh họa tổng quan quy trình học chủ động. Một vòng lặp học chủ động bắt đầu bằng việc huấn luyện mô hình (phần 3.2). Sau đó, với mô hình đã được huấn luyện và một hàm chọn đã được định nghĩa, ta lựa chọn một tập các mẫu từ tập dữ liệu chưa có nhãn (phần 3.3). Các mẫu được chọn sẽ được gán nhãn thông qua kiến thức chuyên gia kết hợp với sự hỗ trợ từ mô hình học sâu đã được huấn luyện (phần 3.4). Các mẫu cùng nhãn tương ứng sau đó được thêm vào tập huấn luyện để bắt đầu vòng lặp tiếp theo. Quy trình học chủ động tiếp tục lặp lại cho đến khi đạt đến một điều kiện dừng nhất định. Điều kiện dừng phổ biến của các quy trình học chủ động thường là số vòng lặp tối đa hoặc khi một ngưỡng hiệu suất đã được thỏa mãn.

3.1 Ký hiệu

Đầu vào của bài toán phân đoạn ảnh là một tensor dữ liệu $\mathbf{x}$ ($\mathbf{x}$ gồm N điểm dữ liệu) và đầu ra là một tensor xác suất $\mathbf{p}$ thể hiện khả năng của từng điểm trong $\mathbf{x}$ có thể thuộc một trong C lớp (class). Từ $\mathbf{p}$, ta thu được *mặt nạ phân đoạn* (segmentation mask) tương ứng của $\mathbf{x}$.

Ta có tập dữ liệu có nhãn $\mathcal{D}_{train} = \{\mathbf{x}^i, \mathbf{y}^i\}_{i=1}^L$ được sử dụng để huấn luyện mô hình chuyên môn (Specialist Model) $\mathcal{M}_s$. Cho một tập dữ liệu



Hình 3.1: Quy trình tổng quát của phương pháp học chủ động

không nhãn $\mathcal{D}_{pool} = \{\mathbf{x}^i\}_{i=1}^U$, bài toán học chủ động (Active Learning) yêu cầu chọn ra một *tập mẫu mới* $\mathcal{Q} \subseteq \mathcal{D}_{pool}$ để gán nhãn và thêm vào $\mathcal{D}_{train}$. Trong đó, L và U lần lượt là kích thước của $\mathcal{D}_{train}$ và $\mathcal{D}_{pool}$ với $L \ll U$. Các mẫu trong $\mathcal{Q}$ được lựa chọn từ $\mathcal{D}_{pool}$ nhằm tăng tối đa độ chính xác của $\mathcal{M}$ huấn luyện trên $\mathcal{D}_{train} \cup \mathcal{Q}$. Vòng lặp *huấn luyện-chọn mẫu* được lặp lại T lần. Tại vòng lặp thứ t , ta ký hiệu *tập dữ liệu có nhãn*, *tập dữ liệu không nhãn*, *tập mẫu được chọn*, và *mô hình chuyên môn* lần lượt là $\mathcal{D}_{train}^t$, $\mathcal{D}_{pool}^t$, $\mathcal{Q}^t$, và $\mathcal{M}^t$.

Tại vòng lặp thứ t , *hàm chọn* $\alpha(\cdot)$ được dùng để lựa chọn b (thường được gọi là ngân sách mẫu) mẫu từ tập $\mathcal{D}_{pool}^{t-1}$. Ở đây, với phương pháp của chúng tôi, *mô hình nền tảng* (Foundation Model) $\mathcal{M}_f$ được tích hợp vào $\alpha(\cdot)$ để tăng hiệu quả của quá trình chọn lựa thông qua việc kết hợp kiến thức tổng quát của $\mathcal{M}_f$ và kiến thức chuyên môn của $\mathcal{M}_s$. Ví dụ, ta có thể sử dụng mô hình U-Net được huấn luyện trên bộ dữ liệu hiện tại làm $\mathcal{M}_s$ và mô hình nền tảng là DINOv2 hoặc BiomedCLIP làm $\mathcal{M}_f$.

3.2 Huấn luyện mô hình

3.2.1 Kiến trúc mô hình

Mô hình học sâu phân đoạn ảnh được chúng tôi sử dụng dựa trên U-Net [16]. U-Net là một mô hình được xây dựng theo dạng hình chữ U và được tạo nên bởi 2 thành phần: *bộ mã hoá* (encoder) và *bộ giải mã* (decoder). U-Net gồm nhiều *tầng* (level) đặc trưng với mỗi *tầng* có tỷ lệ kích thước và số chiều đặc trưng khác nhau. Với kiến trúc hình chữ U, U-Net sử dụng các *kết nối tắt* (skip connection) từ *bộ mã hoá* đến *bộ giải mã* để tăng độ hiệu quả của sự truyền thông giữa các *lớp* (layer) trong mạng học sâu tương tự như ResNet [8].

Cụ thể, mô hình $\mathcal{M}$ có tổng cộng năm *tầng* với số chiều của các *tầng* lần lượt là 32, 64, 128, 256, và 512. Sau mỗi tầng trước tầng cuối cùng, kích thước ảnh sẽ bị giảm đi một nửa trong encoder và được khôi phục lại kích thước như cũ tại tầng tương ứng trong decoder. Tại mỗi tầng, các *khối* (block) trong cả encoder và decoder được tạo nên bởi hai *lớp tích chập* với kích thước kernel là 3×3 . Sau mỗi *lớp tích chập* là một lớp dropout [77], một lớp batchnorm [78], và hàm kích hoạt LeakyReLU. Lớp tích chập đầu tiên của mỗi *tầng* được sử dụng trực tiếp để giảm chiều ảnh trong encoder. Để tăng chiều ảnh, *lớp tích chập đảo* (transpose convolution) được sử dụng trong decoder.

Đầu nhận diện (classifier head) là một lớp tuyến tính được sử dụng với đầu vào là đặc trưng lại lớp cuối của decoder. Đầu ra của *đầu nhận diện* được đưa vào hàm softmax để nhận được vector xác suất của từng pixel trong ảnh thuộc vào mỗi *lớp* tương ứng.

3.2.2 Hàm mục tiêu

Để huấn luyện mô hình phân đoạn ảnh, *hàm lỗi* hay *hàm mục tiêu* được sử dụng dựa trên sự kết hợp của hàm SoftDice và Cross-Entropy. Cụ

thể, ta định nghĩa *hàm mục tiêu* như sau:

$$\mathcal{L} = \mathcal{L}_{SoftDice} + \mathcal{L}_{CE}, \quad (3.1)$$

trong đó

$$\mathcal{L}_{SoftDice} = \frac{1}{C} \sum_{c=0}^{C-1} \left(1 - \frac{2 \sum_{n=1}^N \mathbf{y}_{n,c} \mathbf{p}_{n,c}}{\sum_{n=1}^N \mathbf{y}_{n,c} + \sum_{n=1}^N \mathbf{p}_{n,c}} \right), \quad (3.2)$$

$$\mathcal{L}_{CE} = \frac{1}{N} \sum_{n=1}^N \sum_{c=0}^{C-1} -\mathbf{y}_{n,c} \log \mathbf{p}_{n,c}, \quad (3.3)$$

$\mathbf{p}$ là kết quả sau softmax của $\mathcal{M}_s$, $n \in [1, N]$ là chỉ số của pixel and $c \in [0, C)$ là chỉ số của *lớp*.


$\mathcal{L}_{SoftDice}$ tập trung vào việc tăng độ chính xác trong việc dự đoán mask tổng thể thuộc từng class trong khi $\mathcal{L}_{CE}$ tập trung vào việc cải thiện độ tương đồng của vector xác suất được dự đoán của từng pixel đối với nhãn đúng.

3.3 Chọn lựa mẫu

Hình 3.2 thể hiện phương pháp chọn mẫu của chúng tôi. Đặc trưng từ mô hình chuyên môn $\mathcal{M}_s$ và mô hình nền tảng $\mathcal{M}_f$ được sử dụng để rút trích các đặc trưng tương ứng từ đầu vào. Các đặc trưng sau đó được sử dụng để tạo thành *đặc trưng kết hợp*. Các *đặc trưng kết hợp* được gom cụm bằng thuật toán *k-means++* và trung tâm của các cụm là các mẫu được chọn để gán nhãn.

3.3.1 Tích hợp đặc trưng nền tảng

Đặc trưng nền tảng là các đặc trưng của ảnh được trích xuất từ mô hình nền tảng $\mathcal{M}_f$. Thông thường, các đặc trưng này chứa đựng kiến thức



Hình 3.2: Phương pháp chọn mẫu chủ động

tổng quát được học từ một bộ dữ liệu lớn đã được sử dụng để huấn luyện $\mathcal{M}_f$. Nhờ đó, các *mô hình nền tảng* có khả năng tổng quát hóa cao. Tuy nhiên, *Đặc trưng nền tảng* thường thiếu kiến thức chuyên sâu cần thiết để giải quyết các bài toán đặc thù (ví dụ như phân đoạn ảnh siêu âm).

Trong các bài toán phân tích ảnh y khoa, kiến thức chuyên môn là yếu tố then chốt nhưng lại rất khó để tổng quát hóa, do sự khan hiếm của các bộ dữ liệu lớn (bắt nguồn từ các vấn đề về an toàn và bảo mật) cũng như sự đa dạng đáng kể giữa các tập dữ liệu con (gây ra bởi khác biệt trong thiết bị đo, bác sĩ thực hiện hoặc đặc điểm bệnh nhân).

Do đó, kiến thức tổng quát và kiến thức chuyên môn cần được kết hợp một cách cân trọng nhằm đảm bảo sự cân bằng và phát huy hiệu quả của cả hai loại trong quá trình chọn mẫu dữ liệu trong học chủ động. Ở phần sau, chúng tôi sẽ trình bày chi tiết các bước kết hợp hai loại đặc trưng này về mặt lý thuyết.

Giả sử ta có *đặc trưng nền tảng* $\mathbf{z}_f$ trích xuất từ mô hình $\mathcal{M}_f$ và *đặc trưng chuyên môn* $\mathbf{z}_s$ trích xuất từ mô hình $\mathcal{M}_s$. Đầu tiên, ta xử lý hai đặc trưng trên bằng hàm chuẩn hoá $g(\cdot)$ được định nghĩa như sau:

$$g(\mathbf{x}) = \frac{\mathbf{x} - \hat{\mu}(\mathbf{x})}{\hat{\sigma}(\mathbf{x})}, \quad (3.4)$$

trong đó $\hat{\mu}$ và $\hat{\sigma}$ lần lượt là trung bình mẫu và độ lệch chuẩn mẫu của $\mathbf{x}$ được tính theo công thức sau:

$$\hat{\mu}(\mathbf{x}) = \frac{1}{\dim(\mathbf{x})} \sum_i \mathbf{x}_i \quad (3.5)$$

$$\hat{\sigma}(\mathbf{x}) = \sqrt{\frac{1}{\dim(\mathbf{x}) - 1} \sum_i [\mathbf{x}_i - \hat{\mu}(\mathbf{x})]^2} \quad (3.6)$$

Như vậy, ta thu được hai vector đặc trưng được chuẩn hoá $\hat{\mathbf{z}}_f = g(\mathbf{z}_f)$ và $\hat{\mathbf{z}}_s = g(\mathbf{z}_s)$ lần lượt của $\mathcal{M}_f$ và $\mathcal{M}_s$. Khi đó, ta có thể giả sử rằng các đặc trưng đầu ra của hàm chuẩn hoá tuân theo phân phối chuẩn. Nói cách khác, ta có $\hat{\mathbf{z}}_f \sim \mathcal{N}(0, \mathbf{1})$ và $\hat{\mathbf{z}}_s \sim \mathcal{N}(0, \mathbf{1})$. Việc chuẩn hoá về thông

số thống kê của các đặc trưng đóng vai trò quan trọng vì mặc dù các *mô hình nền tảng* hiện nay có lớp chuẩn hoá (thường là LayerNorm hoặc BatchNorm) ngay trước lớp đầu ra, các đặc trưng thường được *biến đổi afin* (affine transformation). Do đó, các thông số thống kê của các đặc trưng thường khác nhau giữa các mô hình. Các thí nghiệm để chứng minh cho độ hiệu quả và sự cần thiết của hàm chuẩn hoá được báo cáo trong phần [4.6](#).

Nhằm tận dụng khả năng tổng quát hoá của $\mathcal{M}_f$ và sự chính xác trong chuyên môn của $\mathcal{M}_s$, chúng tôi đề xuất sử dụng *đặc trưng kết hợp* $\mathbf{z}$ được tính toán theo công thức sau:

$$\mathbf{z} = \hat{\mathbf{z}}_s \oplus \lambda \hat{\mathbf{z}}_f, \quad (3.7)$$

trong đó

$$\lambda = \sqrt{\delta \cdot \frac{\dim(\hat{\mathbf{z}}_s)}{\dim(\hat{\mathbf{z}}_f)}}, \quad (3.8)$$

$\oplus$ là *phép nối* (concatenate), λ được sử dụng để ràng buộc sự tham gia của $\mathbf{z}_s$ và $\mathbf{z}_f$ vào $\mathbf{z}$. Ngoài ra, để tăng sự tự do trong việc điều chỉnh sự tham gia của các đặc trưng và đặc trưng kết hợp, trọng số của đặc trưng nền tảng δ được áp dụng vào trong công thức [3.8](#).

Ta có thể thấy rằng sự cân bằng giữa khối lượng của các loại đặc trưng là cần thiết vì các đặc trưng từ các mô hình khác nhau thường có số chiều đa dạng và cấu trúc khác nhau. Ví dụ như với các biến thể của DINOv2 [56](#), đầu ra của biến thể ViT-B là một vector 768 chiều, trong khi đối với biến thể ViT-g, đầu ra là một vector 1536.

Để lý giải cho sự cân bằng của các đặc trưng trong công thức [3.8](#), giả sử ta có vector $\mathbf{v} \sim \mathcal{N}(0, \mathbf{I})$ và $\mathbf{v} \in \mathbb{R}^D$. Khi đó:

$$\mathbb{E} [\|\mathbf{v}\|_2^2] = \mathbb{E} \left[\sum_{i=0}^{D-1} \mathbf{v}_i^2 \right] = \sum_{i=0}^{D-1} \mathbb{E} [\mathbf{v}_i^2] = \sum_{i=0}^{D-1} \text{Var}[\mathbf{v}_i] = D = \dim(\mathbf{v}) \quad (3.9)$$

Vì $\mathbb{E} [\|\mathbf{v}\|_2^2]$ tỉ lệ với $\dim(\mathbf{v})$ và việc sử dụng các thước đo như độ tương

đồng cosine hoặc khoảng cách euclid để ước lượng khoảng cách giữa các vector đặc trưng nên để cân bằng sự tham gia của của $\mathbf{z}_s$ và $\mathbf{z}_f$ vào $\mathbf{z}$ ta cần thay đổi tỉ lệ của $\mathbf{z}_f$ với giá trị $\sqrt{\frac{\dim(\mathbf{z}_s)}{\dim(\mathbf{z}_f)}}$.

3.3.2 Hàm chọn

Để lựa chọn tập $\mathcal{Q}^t$ từ $\mathcal{D}_{pool}^{t-1}$, chúng tôi sử dụng thuật toán gom nhóm k -means++ [79] trên *đặc trưng kết hợp* $\mathbf{z}$. Tuy nhiên, vì thuật toán k -means++ mặc định chỉ quan tâm đến sự khác biệt giữa các mẫu trong tập cần gom nhóm $\mathcal{D}_{pool}^{t-1}$ mà bỏ qua khoảng cách tới mẫu có nhãn hiện tại $\mathcal{D}_{train}^{t-1}$ dẫn tới việc lựa chọn mẫu thiếu tối ưu và trùng lặp với tập huấn luyện đã có sẵn. Tuy nhiên, ta có thể điều chỉnh trọng số của từng mẫu dữ liệu trong thuật toán k -means++. Cụ thể, những mẫu dữ liệu có trọng số càng cao thì khả năng được chọn làm trung tâm trong thuật toán k -means++ càng lớn. Vì vậy, ta có thể tích hợp thông tin về khoảng cách giữa mẫu dữ liệu $\mathbf{x}^i$ trong $\mathcal{D}_{pool}^{t-1}$ tới $\mathcal{D}_{train}^{t-1}$ trong vector trọng số mẫu $\mathbf{w}$. Cụ thể, trọng số của mẫu dữ liệu $\mathbf{x}^i$ được tính bằng công thức:

$$\mathbf{w}_i = \min_j \|\mathbf{z}_{pool}^i - \mathbf{z}_{train}^j\|, \quad (3.10)$$

trong đó $\mathbf{z}_{pool}$ và $\mathbf{z}_{train}$ lần lượt là *đặc trưng kết hợp* trong $\mathcal{D}_{pool}^{t-1}$ và $\mathcal{D}_{train}^{t-1}$. Để chuẩn hoá và tăng cường độ tập trung vào các mẫu ở xa đối với $\mathcal{D}_{train}^{t-1}$, $\mathbf{w}^i$ được làm nhọn (sharpen) bằng tham số làm nhọn β như sau:

$$\hat{\mathbf{w}}_i = \frac{(\mathbf{w}_i)^\beta}{\sum_{j=1} (\mathbf{w}_j)^\beta} \quad (3.11)$$

Khi β càng lớn, trọng số trong $\hat{\mathbf{w}}$ sẽ càng tập trung vào các phần tử có giá trị cao hơn phần còn lại trong $\mathbf{w}$, từ đó các mẫu có khoảng cách xa đối với $\mathcal{D}_{train}^{t-1}$ sẽ có trọng số cao hơn nhiều so với các mẫu lân cận với $\mathcal{D}_{train}^{t-1}$.

Vector trọng số mẫu được làm nhọn $\hat{\mathbf{w}}$ sau đó được sử dụng trong thuật toán k -means++ để thu được b cụm khác nhau. Mẫu trung tâm của mỗi


cụm được chọn để thêm vào $\mathcal{Q}^t$ và gán nhãn.

Việc sử dụng thuật toán k -means++ có trọng số $\hat{\mathbf{w}}$ làm hàm chọn $\alpha(\cdot)$ tập trung vào độ đa dạng giữa các mẫu dữ liệu trong $\mathcal{D}_{pool}^{t-1}$ cũng như đối với $\mathcal{D}_{train}^{t-1}$ giúp tăng cường độ đa dạng tổng thể của tập huấn luyện mới $\mathcal{D}_{train}^t = \mathcal{D}_{train}^{t-1} \cup \mathcal{Q}^t$. Từ đó, độ hiệu quả của quá trình huấn luyện của $\mathcal{M}^t$ được tăng lên đáng kể so với $\mathcal{M}^{t-1}$.

3.4 Vòng lặp học chủ động

Vòng lặp thứ t bắt đầu bằng việc chọn mẫu $\mathcal{Q}^t$ với hàm chọn $\alpha(\cdot)$. Các mẫu ảnh trong $\mathcal{Q}^t$ sau đó được gán nhãn bởi *chuyên gia* với sự trợ giúp của $\mathcal{M}_s$. Cụ thể, $\mathcal{M}_s$ sẽ cho ra một *mặt nạ phân đoạn* tương ứng với mỗi ảnh, tuy nhiên các mặt nạ này thường có các điểm sai lệch so với nhãn đúng. Công việc chính của các *chuyên gia* là chỉnh sửa các lỗi sai này thay vì thực hiện việc gán nhãn hoàn toàn từ đầu. Cụ thể, chúng tôi chỉ tập trung vào các lỗi rõ ràng trong *mặt nạ phân đoạn* đầu ra của $\mathcal{M}_s$ bao gồm các *phân mảnh của mặt nạ* và *lỗi biên* của mặt nạ. Trong các ảnh y khoa về siêu âm, mặt nạ của các lớp thường liên tục thành một khối, vì vậy lỗi sai về *phân mảnh của mặt nạ* thường rất tiêu biểu và dễ nhận diện. Ngoài ra, biên của các vật thể (thường là các cơ quan trong cơ thể người) thường mượt và ít gấp khúc, vì vậy chúng tôi tập trung cải thiện độ mượt và liên tục về đường biên của các vật thể. Vì vậy, quá trình gán nhãn và sửa đổi mặt nạ đầu ra của mô hình thường tương đối đơn giản do các lỗi cần xử lý không yêu cầu nhiều kiến thức chuyên môn về y khoa, từ đó giảm gánh nặng về kiến thức cũng như thời gian để gán nhãn các mẫu dữ liệu trong vòng lặp học chủ động.

Sau khi sửa lỗi của các mặt nạ đầu ra, mô hình sẽ được huấn luyện lại trên tập $\mathcal{D}_{train}^t = \mathcal{D}_{train}^{t-1} \cup \mathcal{Q}^t$ và kết thúc một vòng lặp học chủ động. Vòng lặp diễn ra theo quá trình trên tổng cộng T lần.



Hình 3.3: Hậu xử lý đầu ra

3.5 Hậu xử lý đầu ra

Đầu ra của $\mathcal{M}_s$ là một *mặt nạ phân đoạn* với mỗi mẫu dữ liệu. Quá trình *hậu xử lý đầu ra* được mô tả qua hình 3.3 nhằm vào việc giảm thiểu các lỗi tiêu biểu được mô tả ở phần 3.4, nhằm mục đích giảm tải cho quá trình gán nhãn cũng như tăng độ hiệu quả của mô hình phân đoạn ảnh. Cụ thể, để giải quyết vấn đề về *phân mảnh của mặt nạ*, chúng tôi sử dụng thuật toán *xói mòn và giãn nở* (erosion and dilation). Để giảm các vùng phân mảnh nhỏ, chúng tôi bắt đầu bằng việc *xói mòn* mặt nạ, sau đó *giãn nở* mặt nạ các lớp về lại ban đầu. Quá trình ngược lại (*giãn nở* rồi *xói mòn*) được áp dụng sau đó để xóa các lỗ hổng nhỏ trong mặt nạ của các lớp.

Đối với *lỗi biên*, phương pháp làm mềm bằng hàm Gaussian được áp

dụng để tăng độ mượt biên của ảnh phân đoạn. Cụ thể, mặt nạ phân đoạn được làm mờ bằng hàm Guassian nhiều lần rồi lấy ngưỡng nhị phân.

Có thể thấy thông qua mẫu ví dụ ở hình 3.3, những lỗi phân mảnh lớn vẫn còn tồn tại và mặt nạ của hai lớp vẫn còn đan xem vào nhau, nhất là ở phần biên. Vì vậy, việc tham gia của chuyên gia để loại bỏ những lỗi này là cần thiết.

Tuy nhiên, nhờ hai phương pháp trên, các lỗi cơ bản trong mặt nạ phân đoạn được loại bỏ phần lớn. Hơn nữa, vì các lỗi này không chỉ khó nhận diện (do thường rất nhỏ và dễ bỏ qua) mà còn tương đối phổ biến, nhất là ở các vòng lặp đầu tiên của quá trình học chủ động, quá trình điều chỉnh và gán nhãn cho các mẫu dữ liệu trở nên dễ dàng và tiết kiệm nhiều tài nguyên cả về thời gian và công sức nhờ vào sự ứng dụng của quy trình hậu xử lý đầu ra.

Chương 4


Thí nghiệm và kết quả

4.1 Các bộ dữ liệu


Để thử nghiệm độ hiệu quả của phương pháp, chúng tôi đánh giá kết quả trên hai bộ dữ liệu về ảnh siêu âm: (1) Fetal Ultrasound Grand Challenge 2025 (FUGC2025) [80] và (2) Breast Ultrasound Images Dataset (BUSI) [81].

Fetal Ultrasound Grand Challenge 2025

Bộ dữ liệu FUGC2025 được cung cấp trong thử thách về phân đoạn ảnh y khoa thuộc khuôn khổ hội nghị ISBI 2025 tập trung vào việc phân đoạn ảnh vùng cổ tử cung. Cho một ảnh siêu âm vùng cổ tử cung, các thí sinh tham gia được yêu cầu dự đoán mặt nạ phân đoạn thuộc hai lớp: môi trên và môi dưới. Bộ dữ liệu có tổng cộng 500 ảnh trong tập train, 90 ảnh trong tập validation, và 300 ảnh trong tập test. Trong số 500 ảnh của tập train, chỉ có 50 ảnh được cung cấp nhãn đúng, và tất cả các ảnh trong tập validation và tập test đã được gán nhãn sẵn. Các ảnh siêu âm đều có kích thước 544×336 . Ví dụ về các mẫu dữ liệu của bộ dữ liệu FUGC2025 được cung cấp ở trong hình 4.1.




Hình 4.1: Ví dụ về các mẫu dữ liệu trong bộ dữ liệu FUGC2025



Hình 4.2: Ví dụ về các mẫu dữ liệu trong bộ dữ liệu BUSI

Breast Ultrasound Images Dataset

Bộ dữ liệu BUSI gồm tổng cộng 780 ảnh siêu âm vú. Trong đó có 437 ảnh có khối u lành tính, 210 có khối u ác tính, và 133 ảnh bình thường. Vì chỉ có các ảnh có khối u có nhãn, chúng tôi chỉ sử dụng 647 ảnh có nhãn này trong quá trình đánh giá độ hiệu quả của phương pháp. Cụ thể hơn, 452 ảnh (305 u lành tính và 147 u ác tính) được sử dụng trong tập train, 64 ảnh (43 u lành tính và 21 u ác tính) được sử dụng trong tập validation, và 131 ảnh (90 u lành tính và 41 u ác tính) được sử dụng trong tập test.



Hình 4.3: Các phương pháp tăng cường dữ liệu

Kích thước trung bình của các ảnh là 500×500 . Ví dụ về các mẫu dữ liệu trong bộ dữ liệu BUSI được cung cấp ở trong hình [4.2](#).

4.2 Các chi tiết về cài đặt

Để đơn giản hoá, các ảnh đầu vào đều được chuyển đổi về kích thước 256×256 trước khi đưa vào mô hình phân đoạn. Để huấn luyện mô hình phân đoạn $\mathcal{M}_s$, phương pháp tối ưu SGD được sử dụng với $\text{momentum} = 0.9$, $\text{weight_decay} = 0.001$ và huấn luyện trong 4000 epoch. Trong 200 bước tối ưu đầu tiên, kĩ thuật *khởi động tỷ lệ học* (learning rate warmup) được áp dụng để tăng độ ổn định của quá trình huấn luyện bằng việc tăng *tỷ lệ học* tuyến tính từ 0 lên $\text{lr}_0 = 0.01$. Sau đó *tỷ lệ học* được giảm từ từ về 0 bằng hàm đa thức $\text{lr}_i = \text{lr}_0 \cdot (1 - \frac{i}{4000})^{0.9}$. Kích thước của mini-batch trong quá trình huấn luyện là 32.

Dựa trên nnUnet [\[18\]](#), các phương pháp tăng cường dữ liệu sau được áp dụng: (1) tăng giảm kích thước ảnh, (2) xoay ảnh, (3) nhiễu Gaussian, (4)

làm mờ Gaussian, (5) tăng giảm độ sáng, (6) tăng giảm độ tương phản, (7) mô phỏng độ phân giải thấp, và (8) thay đổi gamma. Hình 4.3 thể hiện các mô phỏng của các phương pháp tăng cường dữ liệu được sử dụng trong quá trình huấn luyện mô hình phân đoạn.

Chúng tôi sử dụng $\delta = 2$ và $\beta = 1$ với bộ dữ liệu FUGC2025 và $\delta = 4$ và $\beta = 1$ với bộ dữ liệu BUSI.

Code thực hiện thí nghiệm được công bố tại <https://github.com/trnKhanh/medical-image-analysis>

4.3 Thang đo

Để đánh giá kết quả của phương pháp, chúng tôi sử dụng hệ số Dice-Sørensen (Dice-Sørensen Coefficient - DSC) và hệ số Jaccard (Jaccard Coefficient - JC) để đo lường độ lỗi vùng, và khoảng cách Hausdorff (Hausdorff Distance - HD) và khoảng cách bề mặt trung bình (Average Surface Distance - ASD) để đo lường lỗi biên. Cụ thể, các thang đo trên được định nghĩa như sau:

$$\text{DSC}(\mathcal{X}, \mathcal{Y}) = \frac{2|\mathcal{X} \cap \mathcal{Y}|}{|\mathcal{X}| + |\mathcal{Y}|} \quad (4.1)$$

$$\text{JC}(\mathcal{X}, \mathcal{Y}) = \frac{|\mathcal{X} \cap \mathcal{Y}|}{|\mathcal{X} \cup \mathcal{Y}|} \quad (4.2)$$

$$\text{HD}(\mathcal{X}, \mathcal{Y}) = \max \left(\max_{\mathbf{x} \in \mathcal{X}} \min_{\mathbf{y} \in \mathcal{Y}} \|\mathbf{x} - \mathbf{y}\|, \max_{\mathbf{y} \in \mathcal{Y}} \min_{\mathbf{x} \in \mathcal{X}} \|\mathbf{y} - \mathbf{x}\| \right), \quad (4.3)$$

$$\text{ASD}(\mathcal{X}, \mathcal{Y}) = \frac{1}{|S(\mathcal{X})|} \sum_{\mathbf{x} \in S(\mathcal{X})} \min_{\mathbf{y} \in S(\mathcal{Y})} \|\mathbf{x} - \mathbf{y}\|, \quad (4.4)$$

trong đó $S(A)$ là bề mặt của A .


4.4 Kết quả định lượng

Để đánh giá độ hiệu quả của phương pháp, chúng tôi so sánh với năm phương pháp sau: entropy [45], margin [44], BADGE [50], và coreset [48]. Các thí nghiệm trên bộ dữ liệu FUGC2025 được thử nghiệm trên hai cài đặt ngân sách mẫu khác nhau: $b = 5$ và $b = 10$. Phương pháp đề xuất được phát triển chủ yếu dựa trên bộ dữ liệu FUGC2025 trong khuôn khổ của thử thách tương ứng. Ngoài ra, để đánh giá độ hiệu quả nói chung của phương pháp đề xuất, chúng tôi cũng thực hiện các thử nghiệm trên bộ dữ liệu BUSI với ngân sách $b = 50$. Tất cả các thí nghiệm đều được chạy với $T = 3$ vòng lặp học chủ động do sự hạn chế về phần cứng.


Bảng 4.1: Top 5 team trên bảng xếp hạng được công bố trên codabench của cuộc thi FUGC 2025 (xếp theo DSC). Kết quả của đội chúng tôi được in đậm trong bảng.

Team	DSC (%)↑	HD (pixel)↓	Time (giây)↓
zhangxz	90.26	38.89	652.38
tnk2908	90.08	40.39	315.88
AI VIETNAM	87.18	51.02	428.14
staple	87.03	47.45	394.44
musarrat	86.29	53.98	509.46
maskoff (Baseline)	71.83	115.41	402.40

Hình 4.4 và 4.5 thể hiện kết quả thí nghiệm của các phương pháp học chủ động trên bộ dữ liệu FUGC2025 lần lượt tại hai ngân sách mẫu $b = 5$ và $b = 10$. Với ngân sách mẫu thấp ($b = 5$), phương pháp của chúng tôi hoạt động tốt hơn các phương pháp khác về độ chính xác vùng. Tại vòng lặp chủ động đầu tiên, khi thêm năm mẫu dữ liệu vào tập 50 mẫu có nhãn ban đầu, việc sử dụng các đặc trưng nền tảng khiến mô hình phân đoạn đạt được gần 85% DSC (tăng hơn 8%) và hơn 72.5% JC (tăng khoảng 10%) trong khi phần lớn các phương pháp khác chỉ đạt được gần 80% DSC và 67.5% JC. Hơn nữa, các phương pháp dựa trên ước lượng độ không chắc



Hình 4.4: Kết quả định lượng trên bộ dữ liệu FUGC2025 ($b = 5$)



Hình 4.5: Kết quả định lượng trên bộ dữ liệu FUGC2025 ($b = 10$)

chấn (gồm entropy và margin) có độ chính xác về vùng giảm tương đối trong vòng lặp đầu tiên, nhất là trên độ đo DSC. Tại vòng lặp tiếp theo, phương pháp của chúng tôi tiếp tục cải thiện độ chính xác về vùng trên cả hai thang đo và vượt trội hơn tất cả các phương pháp khác. Tại vòng lặp cuối cùng, phần lớn các phương pháp đều đạt được khoảng 85% và 75%, ngưỡng mà với phương pháp tích hợp mô hình nền tảng đạt được chỉ bằng việc thêm 5 mẫu dữ liệu. Về lỗi biên, tại vòng lặp đầu tiên, độ chính xác của mô hình phân đoạn qua các vòng lặp sử dụng hàm chọn mẫu được đề xuất vượt trội hơn các phương pháp khác, đạt khoảng 80 và 15 lần lượt trên độ đo HD và ASD. Tuy nhiên, tại hai vòng lặp cuối, độ lỗi biên của các phương pháp nhìn chung tương đồng nhau, trong đó vượt trội hơn hết là phương pháp của chúng tôi và coreset. Kết thúc ba vòng lặp chủ động, phần lớn các phương pháp đều đạt được độ lỗi về vùng rơi vào khoảng 70 HD và 13 ASD.

Hình 4.5 thể hiện kết quả của các phương pháp qua các vòng lặp khi ta tăng ngân sách mẫu lên $b = 10$. Tại vòng lặp đầu tiên, phương pháp được đề xuất đạt được khoảng 87% DSC (tăng hơn 10%) và 77.5% JC (tăng khoảng 15%), tốt hơn các phương pháp học chủ động được dùng để so sánh. Tại vòng lặp thứ hai, độ chính xác về vùng của các phương pháp học chủ động tăng không đáng kể, rơi vào khoảng 2% trên cả hai thang đo DSC và JC. Tuy nhiên, tại vòng lặp cuối cùng, phương pháp của chúng tôi có độ chính xác giảm so với vòng lặp thứ hai. Về độ lỗi biên, phương pháp của chúng tôi vượt trội hơn các phương pháp khác ở vòng lặp thứ nhất khi đạt được dưới 70 HD và khoảng 12 ASD. Tương tự như độ chính xác về vùng, chất lượng biên của mô hình phân đoạn huấn luyện dựa trên phương pháp học chủ động được đề xuất giảm ở các vòng lặp cuối. Tại vòng lặp cuối, trên cả các thang đo về vùng và biên, coreset đều đạt được kết quả tốt nhất, chứng minh độ cần thiết của sự đa dạng về mẫu trong bộ dữ liệu huấn luyện đến độ chính xác của mô hình học sâu. Tuy nhiên, với việc ứng dụng các đặc trưng nền tảng chứa các kiến thức tổng quát, mô hình của chúng tôi đạt được kết quả vượt trội hơn hẳn trong các vòng

lập đầu tiên, từ đó giúp tiết kiệm tài nguyên đáng kể bằng cách giới hạn số lượng vòng lặp.

Trên bộ dữ liệu FUGC, các thông số đo định lượng cho thấy rằng với phần lớn các phương pháp, việc chọn ngân sách mẫu có ảnh hưởng lớn đến độ chính xác của mô hình. Cụ thể, với việc chọn ngân sách mẫu lớn $b = 10$, độ chính xác về cả biên lẫn vùng đều đạt được kết quả tốt hơn tại cùng một kích thước bộ dữ liệu huấn luyện. Lấy coreset làm ví dụ, tại $|\mathcal{D}_{train}| = 60$ (tương ứng với vòng lặp thứ hai của $b = 5$ và vòng lặp thứ nhất của $b = 10$), độ chính xác vùng của mô hình phân đoạn đạt được khoảng 87.5% DSC và 77.5% JC tại $b = 10$, cao hơn gần 10% trên cả hai thang đo DSC và JC tại $b = 5$. Đây là một ví dụ trong sự bất ổn định của các phương pháp học chủ động khi việc thay đổi về các tham số của phương pháp có ảnh hưởng lớn đến độ chính xác của mô hình. Hơn nữa, ngân sách mẫu b thấp thường được mong muốn bởi nó giúp cho quá trình đưa ra quyết định (như trả lời câu hỏi "Có tiếp tục gán nhãn nữa không?") trở nên dễ dàng và linh hoạt hơn. Với phương pháp của chúng tôi, nhờ việc tận dụng các kiến thức tổng quát của mô hình học sâu huấn luyện trên các bộ dữ liệu lớn, vấn đề bất ổn định này được giảm thiểu và các tham số nhìn chung ít có ảnh hưởng hơn đến quy trình học. Cụ thể, về độ chính xác vùng, phương pháp của chúng tôi chỉ giảm khoảng 2% trên thang đo DSC và 4% trên thang đo JC khi giảm ngân sách mẫu thay đổi từ $b = 10$ xuống $b = 5$, thấp hơn đáng kể so với phương pháp hoạt động hiệu quả thứ hai là coreset. Điều đó giúp cho quy trình học chủ động của chúng tôi linh hoạt và dễ sử dụng hơn cho người dùng.


Bảng 4.1 là kết quả của năm đội đạt độ chính xác cao nhất của cuộc thi FUGC 2025. So với các đội tham dự khác tại thử thách FUGC 2025, đội của chúng tôi (**tnk2908**) đạt hạng hai khi sửa đổi mặt nạ của toàn bộ bộ dữ liệu không có nhãn. Hơn nữa, về cả độ chính xác vùng và biên, đội chúng tôi có kết quả vượt hơn hẳn đội hạng ba và tương đương với đội hạng nhất trong khi tốc độ chạy vượt phần lớn các đội còn lại. Có thể thấy rằng, chỉ với 60 mẫu dữ liệu (50 mẫu có nhãn + 10 mẫu được tinh

luyện), phương pháp của chúng tôi đã đạt độ chính xác tương đương với đội đạt hạng thứ ba. Khi thêm 10 mẫu được tinh luyện nữa, độ chính xác của phương pháp chúng tôi đã có thể vượt qua đội có kết quả tốt thứ ba.

Hình 4.6 thể hiện kết quả thí nghiệm trên bộ dữ liệu BUSI. Kết quả trên bộ dữ liệu này được sử dụng để đánh giá độ hiệu quả trong việc tổng quát của phương pháp đề xuất vì chúng tôi phát triển phương pháp chủ yếu trên bộ dữ liệu FUGC2025. Hơn nữa, vì BUSI không có tập khởi đầu cố định như với bộ dữ liệu FUGC2025, chúng tôi chọn ngẫu nhiên một tập gồm 50 ảnh với các phương pháp ngoại trừ phương pháp đề xuất. Với sự tích hợp của đặc trưng nền tảng, phương pháp của chúng tôi có thể tận dụng kiến thức tổng quát đó để chọn ra tập mẫu ban đầu bằng tối ưu về độ đa dạng. Vì vậy, ta có thể thấy rằng ở bước đầu tiên, phương pháp được đề xuất có độ hiệu quả vượt hơn các phương pháp còn lại về cả độ chính xác biên và vùng.

Ngược lại với bộ dữ liệu FUGC2025, BADGE có độ chính xác cao so với các phương pháp khác trên bộ dữ liệu BUSI. Phương pháp của chúng tôi nhìn chung có độ chính xác về vùng thấp hơn so với BADGE ở phần lớn các vòng lặp ngoại trừ vòng khởi động. Cụ thể, phương pháp của chúng tôi cùng với BADGE đạt được khoảng 65% DSC và 55% JC tại vòng lặp đầu tiên. Tại vòng lặp thứ hai, về lỗi vùng, phương pháp của chúng tôi, BADGE, và coreset có độ chính xác tương tự nhau. Tuy nhiên, tại vòng lặp cuối cùng, BADGE vượt trội hơn hẳn các phương pháp khác và đạt được gần 72.5% DSC cũng như trên 60% JC trong khi phương pháp của chúng tôi không có cải thiện đáng kể về lỗi vùng. Trên cả hai thang đo, việc chọn mẫu ngẫu nhiên có kết quả trung bình tại các vòng lặp trong khi entropy và margin có độ chính xác bất ổn định về độ chính xác vùng.

Tuy nhiên, về độ chính xác biên, phương pháp của chúng tôi tốt hơn tất cả các phương pháp khác ở phần lớn các vòng lặp chủ động. Với việc chọn mẫu dựa trên đặc trưng nền tảng ở bước khởi động, phương pháp của chúng tôi giảm được hơn 20 HD và 10 ASD so với các phương pháp khác. Ở hai vòng lặp cuối cùng, phương pháp được chúng tôi đề xuất vượt trội




Hình 4.6: Kết quả định lượng trên bộ dữ liệu BUSI

hơn các phương pháp học chủ động khác trên cả hai độ đo HD và ASD khi đạt được khoảng 130 HD và 35 ASD khi kết thúc quy trình học chủ động.


Kết quả của phương pháp của chúng tôi trên hai bộ dữ liệu FUGC và BUSI đôi khi giảm tại các vòng lặp sau, ngược lại với tư tưởng phổ biến rằng khi có càng nhiều mẫu dữ liệu thì độ hiệu quả của mô hình sẽ được cải thiện. Hiện tượng này được biểu hiện rõ ràng nhất trên bộ dữ liệu BUSI khi ở các vòng lặp chủ động sau, độ chính xác về vùng thường có xu hướng chững lại hoặc tệ đi trong khi độ lỗi biên vẫn có cải thiện đáng kể. Một lý giải cho điều này đến từ việc biên của các vật thể (thường là nội tạng) trong các ảnh siêu âm thường mờ và thiếu rõ ràng. Hơn nữa, các vật thể trong ảnh siêu âm cũng có sự biến động rất lớn về hình dạng và kích thước. Vì vậy, ở các vòng lặp sau, phương pháp học chủ động của chúng tôi ưu tiên chọn các mẫu dữ liệu có lợi cho việc cải thiện chất lượng biên mặt nạ, từ đó cải thiện chất lượng biên đáng kể trong khi khiến độ chính xác vùng bị chững lại.

4.5 Kết quả định tính

Hình 4.7 thể hiện chất lượng của mặt nạ phân đoạn qua các vòng lặp học chủ động trên bộ dữ liệu FUGC2025. Mô hình phân đoạn được huấn luyện trên tập dữ liệu khởi đầu có khả năng học được các đặc điểm cơ bản của hai vật thể cần phân đoạn là môi trên và môi dưới của cổ tử cung. Hiện tượng phân mảnh mặt nạ cũng rất phổ biến trong các mặt nạ tại bước khởi động, nhất là của phần môi trên. Ngoài ra, phần biên giữa hai lớp cũng như giữa các vật thể với nền cũng có chất lượng rất thấp. Khi tăng kích thước bộ dữ liệu huấn luyện lên 60, hiện tượng phân mảnh mặt nạ có xu hướng giảm và chất lượng biên của các vật thể tăng đáng kể. Tại $|\mathcal{D}_{train}| = 70$, mô hình phân đoạn có thể đưa ra các mặt nạ nhìn chung liền mạch và có chất lượng tương đối tốt so với mặt nạ đúng, nhất là đối với phần môi dưới của cổ tử cung. Tuy nhiên, đối với phần môi trên, hiện tượng phân mảnh có xu hướng tăng so với vòng lặp trước. Một trong các



Hình 4.7: Kết quả định tính trên bộ dữ liệu FUGC2025



Hình 4.8: Kết quả định tính trên bộ dữ liệu BUSI

lý do có thể đến từ việc phân môi trên trong bộ dữ liệu FUGC2025 có sự đa dạng cao về hình dạng, kích thước, và màu sắc giữa các mẫu dữ liệu khác nhau, dẫn tới việc mô hình phân đoạn lựa chọn việc tốt ưu mặt nạ của phần môi dưới. Tại vòng lặp cuối cùng của quy trình học chủ động, sự phân mảnh của mặt nạ gần như chỉ diễn ra ở phần môi trên và nhìn chung không đáng kể. Vùng biên của các vật thể cũng trở nên mượt hơn, nhất là đường phân chia môi trên và môi dưới. Ta có thể thấy rằng chất lượng của mặt nạ đầu ra của mô hình phân đoạn huấn luyện dựa trên phương pháp học chủ động được chúng tôi đề xuất có chất lượng tương đương với việc huấn luyện trên toàn bộ dữ liệu được cung cấp cũng như dự đoán gần đúng mặt nạ chính xác trong bộ dữ liệu. Điều đó chứng minh được độ hiệu quả của phương pháp học chủ động khi có thể huấn luyện được mô hình có độ chính xác tương đối cao với chỉ 80 mẫu dữ liệu, tương đương với 16% số mẫu trong tập train của bộ dữ liệu FUGC2025. Tuy nhiên, ta có thể thấy rằng nhìn chung mặt nạ đầu ra của các mô hình phân đoạn không đúng hoàn toàn với mặt nạ đúng. Lý do của vấn đề này đến từ cách chúng tôi sử dụng kiến thức của chuyên gia trong quá trình gán nhãn (phần 3.4). Thay vì gán nhãn đúng hoàn toàn cho các mẫu dữ liệu, chúng tôi chỉ sửa đổi các lỗi cơ bản và dễ nhất biết gồm phân mảnh mặt nạ và lỗi biên. Nhờ đó, lượng kiến thức yêu cầu cũng như tài nguyên cần sử dụng được giảm đáng kể trong quá trình gán nhãn và tinh luyện các mặt nạ đầu ra trong quá trình học chủ động.

Hình 4.8 chứa các mặt nạ đầu ra của mô hình phân đoạn qua các vòng lặp chủ động trên bộ dữ liệu BUSI. So với bộ dữ liệu FUGC2025, giữa các mẫu dữ liệu trong bộ dữ liệu BUSI có độ đa dạng cao hơn. Ngoài ra, các khối u thuộc nhiều kích thước và hình dạng khác nhau. Quan trọng nhất là sự tương đồng giữa các vùng khác nhau trong cùng một mẫu dữ liệu về cả kích thước, hình dạng và màu sắc. Các vấn đề trên dẫn tới độ chính xác của mô hình phân đoạn giảm đi đáng kể trên bộ dữ liệu BUSI so với bộ dữ liệu FUGC2025. Tại bước khởi động với 50 mẫu dữ liệu, mô hình học sâu có khả năng nhận diện được các đặc điểm cơ bản của khối u và cho

ra mặt nạ có chất lượng tương đối tốt. Tuy nhiên, ở vòng lặp tiếp theo, chất lượng nhìn chung của các mặt nạ phân đoạn giảm đi đáng kể với hiện tượng phân mảnh trở nên phổ biến hơn. Tại hai vòng lặp sau, mặc dù hiện tượng phân mảnh mặt nạ được giảm thiểu nhưng chất lượng mặt nạ thay đổi không đáng kể so với vòng lặp đầu tiên. Nhìn chung, mô hình phân đoạn qua các vòng lặp chỉ có thể nhận diện chính xác mặt nạ của mẫu dữ liệu thuộc cột số ba trong hình 4.8. Đối với mẫu dữ liệu thứ nhất, tất cả mô hình phân đoạn qua các vòng lặp không thể phát hiện ra khối u và đối với mẫu dữ liệu thứ hai, phần lớn các mô hình đều nhận hiện nhầm chấm đen ở giữa là khối u. Nguyên nhân cho việc bỏ qua khối u tại mẫu dữ liệu thứ nhất có thể đến từ màu sắc và kích thước to bất thường của nó. Còn đối với mẫu dữ liệu thứ hai, màu sắc và hình dạng của chấm đen ở giữa có sự tương đồng cao với các khối u trong bộ dữ liệu nói chung và trong chính mẫu dữ liệu số hai nói riêng.

4.6 Sự ảnh hưởng của các thành phần

Để đánh giá vai trò của các thành phần riêng lẻ đến độ hiệu quả nói chung của phương pháp, chúng tôi thực hiện các thí nghiệm trên bộ dữ liệu FUGC2025 với ngân sách mẫu $b = 10$ diễn ra trong $T = 3$ vòng lặp học chủ động.

Bảng 4.2 thể hiện vai trò của các mô hình nền tảng trong việc chọn mẫu đến độ chính xác của mô hình phân đoạn. Trong phương pháp được chúng tôi đề xuất, việc lựa chọn mô hình nền tảng đóng vai trò quan trọng trong độ chính xác và hiệu quả của quá trình học chủ động, do đó, chúng tôi thử nghiệm trên hai mô hình nền tảng: DINOv2 [56] (đại diện cho các mô hình nền tảng cho ảnh tự nhiên nói chung) và BiomedCLIP [69] (đại diện cho các mô hình nền tảng cho ảnh y khoa nói riêng).

Có thể thấy rằng, độ chính xác của mô hình phân đoạn tăng lên đáng kể khi sử dụng mô hình nền tảng trong quá trình chọn mẫu chủ động trong các vòng lặp sau. Việc thay thế đặc trưng chuyên môn hoàn toàn bằng đặc

Bảng 4.2: Sự ảnh hưởng của các mô hình nền tảng $\mathcal{M}_f$ và sự hiện diện của mô hình chuyên môn $\mathcal{M}_s$ đến độ hiệu quả của quy trình học chủ động.

$\mathcal{M}_f$	$\mathcal{M}_s$	DSC (%) $\uparrow$			JC (%) $\uparrow$		
		60	70	80	60	70	80
-	✓	85.85	87.93	87.25	75.90	78.91	77.99
DINOv2	✗	82.83	85.24	85.53	72.08	75.14	75.52
DINOv2	✓	83.98	86.97	87.81	73.42	77.59	78.80
BiomedCLIP	✗	84.97	87.31	87.78	74.71	78.01	78.70
BiomedCLIP	✓	85.21	88.37	88.28	74.99	79.60	79.45

$\mathcal{M}_f$	$\mathcal{M}_s$	HD (pixels) $\downarrow$			ASD (pixels) $\downarrow$		
		60	70	80	60	70	80
-	✓	69.46	60.09	53.80	12.62	10.10	8.96
DINOv2	✗	69.55	65.81	65.01	13.54	12.32	12.50
DINOv2	✓	72.30	61.18	54.95	13.33	10.92	8.81
BiomedCLIP	✗	75.21	67.02	58.75	14.13	11.65	9.91
BiomedCLIP	✓	75.03	58.63	56.70	13.99	9.79	9.48

Bảng 4.3: Sự ảnh hưởng của trọng số đặc trưng nền tảng s đến độ hiệu quả của phương pháp. Ở đây, chúng tôi thử nghiệm với 5 giá trị δ khác nhau: 0.5, 1.0, 2.0, 8.0, 32.0 với ngân sách mẫu $b = 10$ và tham số làm nhọn $\beta = 1.0$.

δ	DSC (%) $\uparrow$			JC (%) $\uparrow$		
	60	70	80	60	70	80
0.0	85.85	87.93	87.25	75.90	78.91	77.99
0.5	86.22	88.48	88.31	76.33	79.79	79.50
1.0	85.21	88.37	88.28	74.99	79.60	79.45
2.0	86.87	88.77	88.42	77.35	80.23	79.70
8.0	85.70	87.31	87.03	75.67	77.95	77.59
32.0	81.65	86.76	87.59	70.40	77.22	78.45

δ	HD (pixels) $\downarrow$			ASD (pixels) $\downarrow$		
	60	70	80	60	70	80
0.0	69.46	60.09	53.80	12.62	10.10	8.96
0.5	71.24	56.60	54.11	12.90	9.01	8.88
1.0	75.03	58.63	56.70	13.99	9.79	9.48
2.0	65.48	56.87	56.62	11.41	9.27	9.24
8.0	76.81	64.06	56.75	14.54	11.61	10.17
32.0	86.75	66.88	64.88	17.91	12.61	10.66

Bảng 4.4: Sự ảnh hưởng của hàm chuẩn hoá $g(\cdot)$ và tham số làm nhọn β đến độ hiệu quả của quy trình học chủ động.

$g(\cdot)$	δ	β	DSC (%) $\uparrow$			JC (%) $\uparrow$		
			60	70	80	60	70	80
✓	2.0	1.0	86.87	88.77	88.42	77.35	80.23	79.70
✓	2.0	2.0	81.94	87.54	88.18	70.79	78.31	79.32
✓	2.0	4.0	82.01	87.83	87.55	70.92	78.75	78.35
✗	1.0	1.0	84.26	87.26	88.19	73.74	78.05	79.42
✗	1.0	2.0	87.17	87.53	87.60	77.78	78.39	78.47
✗	1.0	4.0	80.84	86.22	87.00	69.51	76.56	77.55
$g(\cdot)$	δ	β	HD (pixels) $\downarrow$			ASD (pixels) $\downarrow$		
			60	70	80	60	70	80
✓	2.0	1.0	65.48	56.87	56.62	11.41	9.27	9.24
✓	2.0	2.0	74.40	61.11	53.74	14.41	10.49	8.54
✓	2.0	4.0	77.32	66.36	58.83	15.16	11.30	10.29
✗	1.0	1.0	79.29	63.66	65.21	15.73	11.18	10.94
✗	1.0	2.0	68.92	68.09	62.76	12.11	12.26	11.08
✗	1.0	4.0	80.78	68.22	66.09	16.37	13.07	11.88

trưng kết hợp của hai loại đặc trưng tăng độ chính xác về vùng trên cả hai thang đo DSC và JC lên từ 2% đến 3% (đối với BiomedCLIP), chứng minh tác động tích cực của mô hình nền tảng đến quy trình học chủ động. Tuy nhiên, đối với đặc trưng DINOv2, trên phần lớn các thang đo về vùng và biên, độ chính xác của quy trình học chủ động có xu hướng giảm rõ rệt, nhất là ở những vòng lặp đầu tiên.

Tuy nhiên, khác với độ chính xác vùng, sự tăng cường trong độ chính xác về biên chủ yếu được thể hiện ở hai vòng lặp chủ động cuối và thay đổi dường như không đáng kể trong vòng lặp đầu. Ngoài ra, đối với cả DINOv2 và BiomedCLIP, việc kết hợp đặc trưng nền tảng với đặc trưng chuyên môn đều có tác động tích cực đến độ chính xác của mô hình khi nó tăng khoảng 1% trên thang đo DSC và JC. Điều này có thể lý giải rằng các kiến thức tổng quát của mô hình nền tảng không có các yếu tố chuyên mô đủ để đánh giá và rút trích đặc trưng trong các tác vụ cụ thể và cần lượng kiến thức từ các mô hình chuyên môn trong quá trình đưa ra quyết định. Giữa hai mô hình nền tảng, BiomedCLIP có chất lượng nhìn chung tốt hơn hẳn so với DINO trên cả độ chính xác về vùng và biên. Sự ưu việt của BiomedCLIP đến từ việc nó được huấn luyện trên một bộ dữ liệu y khoa lớn, dẫn tới việc các kiến thức chuyên môn về y khoa của BiomedCLIP có chất lượng cao hơn so với DINOv2, mô hình được huấn luyện trên bộ dữ liệu ảnh tự nhiên nói chung. Như vậy để đạt được kết quả tốt nhất, việc sử dụng kết hợp giữa đặc trưng nền tảng y khoa (BiomedCLIP) và đặc trưng chuyên môn là cần thiết. Vì vậy, chúng tôi sử dụng BiomedCLIP trong phần lớn các thí nghiệm.

Bảng 4.3 thể hiện sự quan trọng của trọng số đặc trưng nền tảng δ đến độ chính xác nói chung của mô hình. Ở đây, chúng tôi thử nghiệm các giá trị δ khác nhau được chia vào ba loại: (1) không sử dụng đặc trưng nền tảng ($\delta = 0$); (2) đặc trưng nền tảng cân bằng ($0.5 \leq \delta \leq 2$), và (3) đặc trưng nền tảng chiếm ưu thế ($\delta > 2$). Nhìn chung, việc sử dụng đặc trưng nền tảng có tác động tích cực đến quy trình học chủ động, nhất là khi sự cân bằng giữa mô hình chuyên gia và mô hình nền tảng được giữ


vững. Ngoài ra, ta có thể quan sát rằng trọng số đặc trưng nền tảng thấp ($0.5 \leq \delta \leq 2$) không có sự thay đổi nhiều trong độ chính xác vùng và biên. Tuy nhiên khi ta tăng trọng số của đặc trưng nền tảng lên quá cao ($\delta > 2$), độ chính xác giảm đi đáng kể trên mọi thang đo khi giảm khoảng 1% DSC và 2% JC với $\delta = 8.0$ và hơn 4% DSC và 7% JC với $\delta = 32.0$ tại vòng lặp đầu tiên. Ngoài ra, sự ảnh hưởng của δ được quan sát rõ ràng nhất chủ yếu ở vòng lặp đầu tiên và phai nhạt dần ở các vòng lặp sau. Tuy nhiên, đối với các phương pháp học chủ động, độ chính xác của mô hình ở các vòng lặp đầu là vô cùng quan trọng khi các mô hình có thể trợ giúp đáng kể cho các chuyên gia trong quá trình gán nhãn các mẫu dữ liệu được chọn, từ đó tối ưu lượng tài nguyên cần để huấn luyện mô hình. Vì vậy, có thể thấy rằng việc cân bằng giữa hai loại đặc trưng nền tảng và chuyên gia vào đặc trưng kết hợp là vô cùng quan trọng đến độ hiệu quả của phương pháp học chủ động được chúng tôi đề xuất. Dựa trên các kết quả, chúng tôi sử dụng $\delta = 2$ cho phần lớn các thí nghiệm trên bộ dữ liệu FUGC2025.

Bảng 4.4 thể hiện sự ảnh hưởng của hàm chuẩn hoá $g(\cdot)$ cũng như phương pháp làm nhọn đến độ hiệu quả của mô hình. Nhìn chung, khi chuẩn hoá các đặc trưng trước khi kết hợp giúp cải thiện cả độ chính xác về vùng và biên. Cụ thể, hàm chuẩn hoá $g(\cdot)$ giúp tăng khoảng 1% độ chính xác trên cả hai thang đo DSC và JC ở các vòng lặp sau. Trên thang đo về lỗi biên, việc chuẩn hoá giúp giảm khoảng 10 HD và 3. Điều đó cho thấy rằng việc cân bằng về các thông số thống kê của các đặc trưng có ảnh hưởng tích cực đến độ hiệu quả của quá trình chọn mẫu trong vòng lặp chủ động. Khi ta sử dụng phương pháp chuẩn hoá, vai trò của hàm làm nhọn trở nên không quan trọng và thậm chí còn ảnh hưởng tiêu cực đến độ hiệu quả của mô hình khi nó làm giảm khoảng 5% DSC và 7% JC ở vòng lặp đầu tiên. Tuy nhiên, khi không sử dụng hàm chuẩn hoá, việc làm nhọn có ảnh hưởng tương đối tốt đến độ chính xác của mô hình phân đoạn, nhất là ở vòng lặp đầu tiên. Cụ thể, với $\beta = 2$, độ chính xác về vùng tăng khoảng 3% DSC và 4% JC so với việc không sử dụng hàm làm nhọn ($\beta = 1$). Tuy nhiên, khi ta làm nhọn vector trọng số quá nhiều ($\beta = 4$), độ


chính xác của mô hình về cả vùng lẫn biên đều giảm đáng kể. Vì vậy, việc cân bằng tham số làm nhọn β rất quan trọng đến độ hiệu quả của phương pháp học chủ động của chúng tôi. Về mặt lý thuyết, tham số β đại diện cho sự đánh đổi giữa sự đa dạng nội tại trong tập mẫu dữ liệu được chọn $\mathcal{Q}$ và sự đa dạng của tập mẫu dữ liệu được chọn $\mathcal{Q}$ đến tập huấn luyện hiện tại $\mathcal{D}_{train}$. Ngoài ra, có thể thấy rằng mặc dù hàm làm nhọn không có ảnh hưởng nhiều khi ta sử dụng hàm chuẩn hoá trong quá trình kết hợp các loại đặc trưng, việc hiện diện của tham số làm nhọn β giúp người dùng có khả năng điều chỉnh thuật toán một cách linh hoạt tùy theo bộ dữ liệu, từ đó có thể giúp cải thiện độ chính xác của mô hình tùy thuộc vào từng tình huống cụ thể.

4.7 Mô phỏng đặc trưng


Hình 4.9 thể hiện các đặc trưng của các mô hình được mô phỏng bằng thuật toán t-SNE trên bộ dữ liệu FUGC2025. Ở đây, màu của các điểm đại diện cho chỉ số cụm của nó trong bộ dữ liệu FUGC2025, được xác định một cách thủ công để đảm bảo độ chính xác cao. Cụ thể, chúng tôi tiến hành quan sát các mẫu dữ liệu trong bộ dữ liệu FUGC2025 và phân các mẫu dữ liệu về 15 cụm khác nhau. Các cụm dữ liệu này chứa các mẫu có độ tương đồng cao về hình dạng và màu sắc. Nhìn chung, các đặc trưng tổng quát (hình (b) và (c)) có phân bố rải rác hơn so với đặc trưng chuyên môn (hình (a)). Đây là ví dụ cho sự bao quát của các đặc trưng nền tảng khi và cũng tiêu biểu cho một hạn chế của mô hình nền tảng trong việc phân biệt các đặc trưng thuộc các tác vụ cụ thể. Sự phân bố của các đặc trưng rút trích bằng BiomedCLIP nói chung có sự phân biệt rõ ràng hơn giữa các cụm dữ liệu so với DINOv2. Đối với đặc trưng chuyên môn, các mẫu dữ liệu thuộc về cùng một cụm thường phân bố gần nhau hơn, nhưng giữa các mẫu dữ liệu ít có sự phân biệt một cách rõ ràng. Sự kết hợp giữa đặc trưng nền tảng và chuyên môn phần nào giúp cân bằng điểm mạnh và điểm yếu của hai loại đặc trưng này. Ta có thể thấy ở hình (d) rằng các




(a) $\mathcal{M}_s:\checkmark$ $\mathcal{M}_f:\times$



(b) $\mathcal{M}_s:\times$ $\mathcal{M}_f:\text{DINOv2}$



(c) $\mathcal{M}_s:\times$ $\mathcal{M}_f:\text{BiomedCLIP}$



(d) $\mathcal{M}_s:\checkmark$ $\mathcal{M}_f:\text{BiomedCLIP}$

Hình 4.9: Các đặc trưng mô phỏng bằng thuật toán t-SNE.

đặc trưng kết hợp không chỉ phân bố tập trung vào các cụm dữ liệu mà giữa các cụm dữ liệu cũng có sự phân bố rõ ràng hơn. Nhờ vậy, thuật toán *k-means++* chạy trên đặc trưng kết hợp này có thể đạt được kết quả tốt nhất trong việc tạo nên một bộ dữ liệu huấn luyện đa dạng và hàm chứa lượng lớn thông tin của bộ dữ liệu tổng.

Chương 5

Kết luận

Các phương pháp học chủ động ngày càng nhận được sự quan tâm lớn nhờ khả năng sử dụng hiệu quả dữ liệu và tài nguyên trong quá trình huấn luyện các mô hình học sâu. Điều này càng trở nên quan trọng hơn trong lĩnh vực dữ liệu y khoa, khi chi phí gán nhãn ảnh thường rất cao do yêu cầu về kinh nghiệm và kiến thức chuyên môn sâu của các bác sĩ. Bên cạnh đó, các vấn đề liên quan đến bảo vệ quyền riêng tư của bệnh nhân cũng hạn chế việc công bố các bộ dữ liệu quy mô lớn, từ đó làm chậm quá trình phát triển của các phương pháp học máy nói chung.

Trước thực trạng đó, chúng tôi đề xuất một phương pháp kết hợp các mô hình nền tảng có sẵn (thường được huấn luyện trên các bộ dữ liệu lớn) vào quy trình học chủ động nhằm tận dụng đồng thời kiến thức tổng quát và kiến thức chuyên môn trong việc lựa chọn mẫu dữ liệu. Nhờ vậy, phương pháp của chúng tôi có thể tối ưu hóa hiệu quả của mô hình học sâu trong khi giảm thiểu lượng tài nguyên cần thiết cho quá trình gán nhãn.

Thông qua các thực nghiệm và so sánh với các phương pháp học chủ động khác, phương pháp của chúng tôi cho thấy kết quả vượt trội nhờ sự kết hợp hiệu quả giữa kiến thức nền tảng và kiến thức chuyên môn, khẳng định rằng kiến thức tổng quát có ảnh hưởng tích cực đến quá trình chọn mẫu trong học chủ động.

Tuy nhiên, phương pháp vẫn còn tồn tại một số hạn chế. Thứ nhất, quá trình gán nhãn hiện tại còn thiếu sự tương tác trực tiếp giữa chuyên

gia và mô hình, dẫn đến thời gian gán nhãn kéo dài và chưa tận dụng tối đa kiến thức chuyên gia. Việc tích hợp các phương pháp tương tác (chẳng hạn như SAM) có thể giúp đẩy nhanh quá trình gán nhãn và nâng cao hiệu quả. Hạn chế thứ hai nằm ở việc lựa chọn và tối ưu các tham số trong phương pháp của chúng tôi (cụ thể là β và δ). Dù các tham số này mang lại sự linh hoạt cho người dùng trong việc điều chỉnh quy trình học chủ động, nhưng cũng làm tăng độ phức tạp trong việc tối ưu, nhất là trong bối cảnh học chủ động thường chỉ cho phép một lần thực hiện vòng lặp. Hơn nữa, phương pháp học chủ động hiện tại đang có sự hạn chế về sự tường minh và tính lý giải cho người sử dụng. Điều đó không chỉ khiến cho quá trình học chủ động gặp nhiều hạn chế trong sự giao tiếp giữa mô hình học và người gán nhãn.

Do đó, các hướng phát triển trong tương lai có thể tập trung vào việc khắc phục các hạn chế nêu trên. Ngoài ra, hiện nay hầu hết các phương pháp học chủ động chỉ cập nhật mô hình sau mỗi vòng lặp, khiến các mẫu đã được gán nhãn chỉ phát huy hiệu quả sau khi kết thúc vòng lặp. Việc tích hợp các phương pháp thích nghi trong thời gian kiểm tra (test-time adaptation) có thể giúp cải thiện hiệu quả của mô hình ngay trong quá trình gán nhãn. Điều này không chỉ giúp tăng tốc độ gán nhãn mà còn tối ưu hóa việc sử dụng tài nguyên về mặt thời gian và công sức.

Danh mục công trình của tác giả

1. IEEE International Symposium on Biomedical Imaging (IEEE ISBI) 2025 (Grand Challenge Paper)

- **ERA2010 Ranking:** A
- **h5-index** (Google Scholar): 53
- **Tình trạng:** đã đăng
- **Tên:** Human-in-the-Loop Semi-Supervised Uterine Cervix Ultrasound Image Segmentation
- **Bài báo:** <https://ieeexplore.ieee.org/document/10981068>

2. International Conference on Machine Vision (ICMV) 2025 (Full Paper)

- **CORE2023 Ranking:** C
- **h5-index** (Google Scholar): 17
- **Tình trạng:** đã được nhận đăng
- **Tên:** Foundation-Guided Active Learning for Efficient Ultrasound Image Segmentation
- **Thư chấp nhận:** <https://bit.ly/3TX1fUx>

Tài liệu tham khảo

Tiếng Anh

- [1] Schmidt, R. M., “Recurrent neural networks (rnns): A gentle introduction and overview,” *arXiv preprint arXiv:1912.05911*, 2019.
- [2] Vaswani, A., Shazeer, N., Parmar, N., *et al.*, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [3] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K., “Bert: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, 2019, pp. 4171–4186.
- [4] Yenduri, G., Ramalingam, M., Selvi, G. C., *et al.*, “Gpt (generative pre-trained transformer)—a comprehensive review on enabling technologies, potential applications, emerging challenges, and future directions,” *IEEE Access*, 2024.
- [5] Nareklishvili, M., Polson, N., and Sokolov, V., “Generative modeling: A review,” *arXiv preprint arXiv:2501.05458*, 2024.
- [6] Goodfellow, I., Pouget-Abadie, J., Mirza, M., *et al.*, “Generative adversarial networks,” *Communications of the ACM*, vol. 63, no. 11, pp. 139–144, 2020.

- [7] Ho, J., Jain, A., and Abbeel, P., “Denoising diffusion probabilistic models,” *Advances in neural information processing systems*, vol. 33, pp. 6840–6851, 2020.
- [8] He, K., Zhang, X., Ren, S., and Sun, J., “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2016.
- [9] Tan, M. and Le, Q., “Efficientnet: Rethinking model scaling for convolutional neural networks,” in *International conference on machine learning*, PMLR, 2019, pp. 6105–6114.
- [10] Dosovitskiy, A., Beyer, L., Kolesnikov, A., *et al.*, “An image is worth 16x16 words: Transformers for image recognition at scale,” in *International Conference on Learning Representations*, 2021. [Online]. Available: <https://openreview.net/forum?id=YicbFdNTTy>.
- [11] Touvron, H., Cord, M., Douze, M., Massa, F., Sablayrolles, A., and Jégou, H., “Training data-efficient image transformers & distillation through attention,” in *International conference on machine learning*, PMLR, 2021, pp. 10 347–10 357.
- [12] Sun, C., Shrivastava, A., Singh, S., and Gupta, A., “Revisiting unreasonable effectiveness of data in deep learning era,” in *Proceedings of the IEEE international conference on computer vision*, 2017, pp. 843–852.
- [13] Russakovsky, O., Deng, J., Su, H., *et al.*, “Imagenet large scale visual recognition challenge,” *International journal of computer vision*, vol. 115, pp. 211–252, 2015.
- [14] Radford, A., Kim, J. W., Hallacy, C., *et al.*, “Learning transferable visual models from natural language supervision,” in *International conference on machine learning*, PmLR, 2021, pp. 8748–8763.

- [15] Simonyan, K. and Zisserman, A., “Very deep convolutional networks for large-scale image recognition,” *arXiv preprint arXiv:1409.1556*, 2014.
- [16] Ronneberger, O., Fischer, P., and Brox, T., “U-net: Convolutional networks for biomedical image segmentation,” in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, Navab, N., Hornegger, J., Wells, W. M., and Frangi, A. F., Eds., Cham: Springer International Publishing, 2015, pp. 234–241, ISBN: 978-3-319-24574-4.
- [17] Milletari, F., Navab, N., and Ahmadi, S.-A., “V-net: Fully convolutional neural networks for volumetric medical image segmentation,” in *2016 fourth international conference on 3D vision (3DV)*, Ieee, 2016, pp. 565–571.
- [18] Isensee, F., Jaeger, P. F., Kohl, S. A. A., Petersen, J., and Maier-Hein, K. H., “Nnu-net: A self-configuring method for deep learning-based biomedical image segmentation,” *Nature Methods*, vol. 18, no. 2, pp. 203–211, Feb. 2021, ISSN: 1548-7105. DOI: [10.1038/s41592-020-01008-z](https://doi.org/10.1038/s41592-020-01008-z). [Online]. Available: <https://doi.org/10.1038/s41592-020-01008-z>.
- [19] Chen, J., Mei, J., Li, X., *et al.*, “Transunet: Rethinking the u-net architecture design for medical image segmentation through the lens of transformers,” *Medical Image Analysis*, vol. 97, p. 103 280, 2024.
- [20] Cao, H., Wang, Y., Chen, J., *et al.*, “Swin-unet: Unet-like pure transformer for medical image segmentation,” in *European conference on computer vision*, Springer, 2022, pp. 205–218.
- [21] Hatamizadeh, A., Nath, V., Tang, Y., Yang, D., Roth, H. R., and Xu, D., “Swin unetr: Swin transformers for semantic segmentation of brain tumors in mri images,” in *International MICCAI brainlesion workshop*, Springer, 2021, pp. 272–284.

- [22] Yan, K., Wang, X., Lu, L., and Summers, R. M., *Deeplesion: Automated deep mining, categorization and detection of significant radiology image findings using large-scale clinical lesion annotations*, 2017. arXiv: [1710.01766 \[cs.CV\]](https://arxiv.org/abs/1710.01766). [Online]. Available: <https://arxiv.org/abs/1710.01766>.
- [23] Baumgartner, M., Jäger, P. F., Isensee, F., and Maier-Hein, K. H., “Nndetection: A self-configuring method for medical object detection,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2021*. Springer International Publishing, 2021, pp. 530–539, ISBN: 9783030872403. DOI: [10.1007/978-3-030-87240-3_51](https://doi.org/10.1007/978-3-030-87240-3_51). [Online]. Available: http://dx.doi.org/10.1007/978-3-030-87240-3_51.
- [24] DiPietro, R. and Hager, G. D., “Deep learning: Rnns and lstm,” in *Handbook of medical image computing and computer assisted intervention*, Elsevier, 2020, pp. 503–519.
- [25] Chung, J., Gulcehre, C., Cho, K., and Bengio, Y., “Empirical evaluation of gated recurrent neural networks on sequence modeling,” *arXiv preprint arXiv:1412.3555*, 2014.
- [26] Lu, Y., Aslani, S., Zhao, A., *et al.*, “A hybrid cnn-rnn approach for survival analysis in a lung cancer screening study,” *Heliyon*, vol. 9, no. 8, 2023.
- [27] Ballinger, B., Hsieh, J., Singh, A., *et al.*, “Deepheart: Semi-supervised sequence learning for cardiovascular risk prediction,” in *Proceedings of the AAAI conference on artificial intelligence*, vol. 32, 2018.
- [28] Supratak, A., Dong, H., Wu, C., and Guo, Y., “Deepsleepnet: A model for automatic sleep stage scoring based on raw single-channel eeg,” *IEEE transactions on neural systems and rehabilitation engineering*, vol. 25, no. 11, pp. 1998–2008, 2017.

- [29] Zhuang, F., Qi, Z., Duan, K., *et al.*, “A comprehensive survey on transfer learning,” *Proceedings of the IEEE*, vol. 109, no. 1, pp. 43–76, 2020.
- [30] Bharati, S., Mondal, M. R. H., Podder, P., and Prasath, V. S., “Federated learning: Applications, challenges and future directions,” *International Journal of Hybrid Intelligent Systems*, vol. 18, no. 1–2, pp. 19–35, May 2022, ISSN: 1875-8819. DOI: [10.3233/his-220006](https://doi.org/10.3233/his-220006). [Online]. Available: <http://dx.doi.org/10.3233/HIS-220006>.
- [31] Jiao, R., Zhang, Y., Ding, L., *et al.*, “Learning with limited annotations: A survey on deep semi-supervised learning for medical image segmentation,” *Computers in Biology and Medicine*, vol. 169, p. 107840, 2024.
- [32] Hou, J., Liu, S., Bie, Y., *et al.*, *Self-explainable ai for medical image analysis: A survey and new outlooks*, 2024. arXiv: [2410.02331](https://arxiv.org/abs/2410.02331) [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2410.02331>.
- [33] Zhou, Z., Rahman Siddiquee, M. M., Tajbakhsh, N., and Liang, J., “Unet++: A nested u-net architecture for medical image segmentation,” in *Deep learning in medical image analysis and multimodal learning for clinical decision support: 4th international workshop, DLMIA 2018, and 8th international workshop, ML-CDS 2018, held in conjunction with MICCAI 2018, Granada, Spain, September 20, 2018, proceedings 4*, Springer, 2018, pp. 3–11.
- [34] Oktay, O., Schlemper, J., Folgoc, L. L., *et al.*, “Attention u-net: Learning where to look for the pancreas,” in *Medical Imaging with Deep Learning*, 2018. [Online]. Available: <https://openreview.net/forum?id=Skft7cijM>.
- [35] Diakogiannis, F. I., Waldner, F., Caccetta, P., and Wu, C., “Resunet-a: A deep learning framework for semantic segmentation of remotely sensed data,” *ISPRS Journal of Photogrammetry and Remote Sens-*

- ing, vol. 162, pp. 94–114, Apr. 2020, ISSN: 0924-2716. DOI: [10.1016/j.isprsjprs.2020.01.013](https://doi.org/10.1016/j.isprsjprs.2020.01.013). [Online]. Available: <http://dx.doi.org/10.1016/j.isprsjprs.2020.01.013>.
- [36] Hatamizadeh, A., Tang, Y., Nath, V., *et al.*, “Unetr: Transformers for 3d medical image segmentation,” in *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, 2022, pp. 574–584.
 - [37] Liu, Z., Lin, Y., Cao, Y., *et al.*, “Swin transformer: Hierarchical vision transformer using shifted windows,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 10 012–10 022.
 - [38] Shaker, A., Maaz, M., Rasheed, H., Khan, S., Yang, M.-H., and Khan, F. S., “Unetr++: Delving into efficient and accurate 3d medical image segmentation,” *IEEE Transactions on Medical Imaging*, vol. 43, no. 9, pp. 3377–3390, 2024.
 - [39] Wu, X., Xiao, L., Sun, Y., Zhang, J., Ma, T., and He, L., “A survey of human-in-the-loop for machine learning,” *Future Generation Computer Systems*, vol. 135, pp. 364–381, Oct. 2022, ISSN: 0167-739X. DOI: [10.1016/j.future.2022.05.014](https://doi.org/10.1016/j.future.2022.05.014). [Online]. Available: <http://dx.doi.org/10.1016/j.future.2022.05.014>.
 - [40] Zhu, J. and Wu, J., *Meduhip: Towards human-in-the-loop medical segmentation*, 2024. arXiv: [2408.01620 \[eess.IV\]](https://arxiv.org/abs/2408.01620). [Online]. Available: <https://arxiv.org/abs/2408.01620>.
 - [41] Li, H., Oguz, B., Arenas, G., *et al.*, “Prism lite: A lightweight model for interactive 3d placenta segmentation in ultrasound,” in *Medical Imaging 2025: Image Processing*, SPIE, vol. 13406, 2025, pp. 65–70.
 - [42] Rusu, A. A., Rabinowitz, N. C., Desjardins, G., *et al.*, *Progressive neural networks*, 2022. arXiv: [1606.04671 \[cs.LG\]](https://arxiv.org/abs/1606.04671). [Online]. Available: <https://arxiv.org/abs/1606.04671>.

- [43] Li, D., Wang, Z., Chen, Y., Jiang, R., Ding, W., and Okumura, M., “A survey on deep active learning: Recent advances and new frontiers,” *IEEE Transactions on Neural Networks and Learning Systems*, 2024.
- [44] Roth, D. and Small, K., “Margin-based active learning for structured output spaces,” in *Machine Learning: ECML 2006*, Fürnkranz, J., Scheffer, T., and Spiliopoulou, M., Eds., Berlin, Heidelberg: Springer Berlin Heidelberg, 2006, pp. 413–424.
- [45] Joshi, A. J., Porikli, F., and Papanikolopoulos, N., “Multi-class active learning for image classification,” in *2009 IEEE Conference on Computer Vision and Pattern Recognition*, 2009, pp. 2372–2379. DOI: [10.1109/CVPR.2009.5206627](https://doi.org/10.1109/CVPR.2009.5206627).
- [46] Houlshby, N., Huszár, F., Ghahramani, Z., and Lengyel, M., “Bayesian active learning for classification and preference learning,” *arXiv preprint arXiv:1112.5745*, 2011.
- [47] Gal, Y., Islam, R., and Ghahramani, Z., “Deep bayesian active learning with image data,” in *International conference on machine learning*, PMLR, 2017, pp. 1183–1192.
- [48] Sener, O. and Savarese, S., “Active learning for convolutional neural networks: A core-set approach,” in *International Conference on Learning Representations*, 2018. [Online]. Available: <https://openreview.net/forum?id=H1aIuk-RW>.
- [49] Citovsky, G., DeSalvo, G., Gentile, C., *et al.*, “Batch active learning at scale,” in *Advances in Neural Information Processing Systems*, Ranzato, M., Beygelzimer, A., Dauphin, Y., Liang, P., and Vaughan, J. W., Eds., vol. 34, Curran Associates, Inc., 2021, pp. 11 933–11 944. [Online]. Available: https://proceedings.neurips.cc/paper_files/paper/2021/file/64254db8396e404d9223914a0bd355d2-Paper.pdf.

- [50] Ash, J. T., Zhang, C., Krishnamurthy, A., Langford, J., and Agarwal, A., “Deep batch active learning by diverse, uncertain gradient lower bounds,” in *International Conference on Learning Representations*, 2020. [Online]. Available: <https://openreview.net/pdf?id=ryghZJBKPS>.
- [51] Sinha, S., Ebrahimi, S., and Darrell, T., “Variational adversarial active learning,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2019, pp. 5972–5981.
- [52] Qiu, J., Wilm, F., Öttl, M., *et al.*, “Adaptive region selection for active learning in whole slide image semantic segmentation,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*, Greenspan, H., Madabhushi, A., Mousavi, P., *et al.*, Eds., Cham: Springer Nature Switzerland, 2023, pp. 90–100, ISBN: 978-3-031-43895-0.
- [53] Tang, Y., Hu, Y., Li, J., *et al.*, “Pld-al: Pseudo-label divergence-based active learning in carotid intima-media segmentation for ultrasound images,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2023*, Greenspan, H., Madabhushi, A., Mousavi, P., *et al.*, Eds., Cham: Springer Nature Switzerland, 2023, pp. 57–67, ISBN: 978-3-031-43895-0.
- [54] Balaram, S., Nguyen, C. M., Kassim, A., and Krishnaswamy, P., “Consistency-based semi-supervised evidential active learning for diagnostic radiograph classification,” in *Medical Image Computing and Computer Assisted Intervention – MICCAI 2022*, Wang, L., Dou, Q., Fletcher, P. T., Speidel, S., and Li, S., Eds., Cham: Springer Nature Switzerland, 2022, pp. 675–685, ISBN: 978-3-031-16431-6.
- [55] Li, X., Xia, M., Jiao, J., *et al.*, “Hal-ia: A hybrid active learning framework using interactive annotation for medical image segmentation,” *Medical Image Analysis*, vol. 88, p. 102 862, 2023, ISSN: 1361-8415. DOI: <https://doi.org/10.1016/j.media.2023.102862>.

- [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S1361841523001226>.
- [56] Oquab, M., Darcet, T., Moutakanni, T., *et al.*, *Dinov2: Learning robust visual features without supervision*, 2023.
 - [57] Caron, M., Touvron, H., Misra, I., *et al.*, “Emerging properties in self-supervised vision transformers,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2021, pp. 9650–9660.
 - [58] Kirillov, A., Mintun, E., Ravi, N., *et al.*, “Segment anything,” in *Proceedings of the IEEE/CVF international conference on computer vision*, 2023, pp. 4015–4026.
 - [59] He, K., Chen, X., Xie, S., Li, Y., Dollár, P., and Girshick, R., “Masked autoencoders are scalable vision learners,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 16 000–16 009.
 - [60] Chen, T., Kornblith, S., Norouzi, M., and Hinton, G., “A simple framework for contrastive learning of visual representations,” in *International conference on machine learning*, PmLR, 2020, pp. 1597–1607.
 - [61] He, K., Fan, H., Wu, Y., Xie, S., and Girshick, R., “Momentum contrast for unsupervised visual representation learning,” in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 9729–9738.
 - [62] Bao, H., Dong, L., Piao, S., and Wei, F., “BEit: BERT pre-training of image transformers,” in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=p-BhZSz59o4>.
 - [63] Huang, G., Liu, Z., Van Der Maaten, L., and Weinberger, K. Q., “Densely connected convolutional networks,” in *Proceedings of the*

- IEEE conference on computer vision and pattern recognition*, 2017, pp. 4700–4708.
- [64] Chen, L.-C., Papandreou, G., Kokkinos, I., Murphy, K., and Yuille, A. L., “Deeplab: Semantic image segmentation with deep convolutional nets, atrous convolution, and fully connected crfs,” *IEEE transactions on pattern analysis and machine intelligence*, vol. 40, no. 4, pp. 834–848, 2017.
 - [65] Schuhmann, C., Beaumont, R., Vencu, R., *et al.*, “Laion-5b: An open large-scale dataset for training next generation image-text models,” *Advances in neural information processing systems*, vol. 35, pp. 25 278–25 294, 2022.
 - [66] Ma, J., He, Y., Li, F., Han, L., You, C., and Wang, B., “Segment anything in medical images,” *Nature Communications*, vol. 15, no. 1, Jan. 2024, ISSN: 2041-1723. DOI: [10.1038/s41467-024-44824-z](https://doi.org/10.1038/s41467-024-44824-z). [Online]. Available: <http://dx.doi.org/10.1038/s41467-024-44824-z>.
 - [67] Zhang, K. and Liu, D., “Customized segment anything model for medical image segmentation,” *arXiv preprint arXiv:2304.13785*, 2023.
 - [68] Lin, X., Xiang, Y., Yu, L., and Yan, Z., “Beyond adapting sam: Towards end-to-end ultrasound image segmentation via auto prompting,” in *International Conference on Medical Image Computing and Computer-Assisted Intervention*, Springer, 2024, pp. 24–34.
 - [69] Zhang, S., Xu, Y., Usuyama, N., *et al.*, *Biomedclip: A multimodal biomedical foundation model pretrained from fifteen million scientific image-text pairs*, 2025. arXiv: [2303.00915 \[cs.CV\]](https://arxiv.org/abs/2303.00915). [Online]. Available: <https://arxiv.org/abs/2303.00915>.
 - [70] Lu, M. Y., Chen, B., Williamson, D. F. K., *et al.*, *Towards a visual-language foundation model for computational pathology*, 2023. arXiv:

2307.12914 [cs.CV]. [Online]. Available: <https://arxiv.org/abs/2307.12914>.

- [71] Tomczak, K., Czerwińska, P., and Wiznerowicz, M., “Review the cancer genome atlas (tcga): An immeasurable source of knowledge,” *Contemporary Oncology/Współczesna Onkologia*, vol. 2015, no. 1, pp. 68–77, 2015.
- [72] Litjens, G., Bandi, P., Ehteshami Bejnordi, B., *et al.*, “1399 h&e-stained sentinel lymph node sections of breast cancer patients: The camelyon dataset,” *GigaScience*, vol. 7, no. 6, giy065, 2018.
- [73] Trisnadi, J. I., “Speckle contrast reduction in laser projection displays,” in *Projection Displays VIII*, Wu, M. H., Ed., International Society for Optics and Photonics, vol. 4657, SPIE, 2002, pp. 131–137. DOI: [10.1117/12.463781](https://doi.org/10.1117/12.463781). [Online]. Available: <https://doi.org/10.1117/12.463781>.
- [74] Taha, A. A. and Hanbury, A., “Metrics for evaluating 3d medical image segmentation: Analysis, selection, and tool,” *BMC medical imaging*, vol. 15, no. 1, pp. 1–28, 2015.
- [75] Huttenlocher, D. P., Klanderman, G. A., and Rucklidge, W. J., “Comparing images using the hausdorff distance,” *IEEE Transactions on pattern analysis and machine intelligence*, vol. 15, no. 9, pp. 850–863, 1993.
- [76] Zhang, Z. and Bagci, U., *Segmentation quality and volumetric accuracy in medical imaging*, 2024. arXiv: [2404.17742 \[eess.IV\]](https://arxiv.org/abs/2404.17742). [Online]. Available: <https://arxiv.org/abs/2404.17742>.
- [77] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., and Salakhutdinov, R., “Dropout: A simple way to prevent neural networks from overfitting,” *J. Mach. Learn. Res.*, vol. 15, no. 1, pp. 1929–1958, Jan. 2014, ISSN: 1532-4435.

- [78] Ioffe, S. and Szegedy, C., “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” in *Proceedings of the 32nd International Conference on International Conference on Machine Learning - Volume 37*, ser. ICML’15, Lille, France: JMLR.org, 2015, pp. 448–456.
- [79] Arthur, D. and Vassilvitskii, S., “K-means++: The advantages of careful seeding,” in *Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms*, ser. SODA ’07, New Orleans, Louisiana: Society for Industrial and Applied Mathematics, 2007, pp. 1027–1035, ISBN: 9780898716245.
- [80] Bai, J., Yang, Z., Hasan, K., *et al.*, *Fetal ultrasound grand challenge: Semi-supervised cervical segmentation (fugc25)*, Dec. 2024. DOI: [10.5281/zenodo.14328192](https://doi.org/10.5281/zenodo.14328192).
- [81] Al-Dhabyani, W., Gomaa, M., Khaled, H., and Fahmy, A., “Dataset of breast ultrasound images,” *Data in Brief*, vol. 28, p. 104863, 2020, ISSN: 2352-3409. DOI: <https://doi.org/10.1016/j.dib.2019.104863>. [Online]. Available: <https://www.sciencedirect.com/science/article/pii/S2352340919312181>.